

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ – TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



KHÓA LUẬN TỐT NGHIỆP

PHÂN ĐOẠN ẢNH TUYÊN TỤY TRÊN
CƠ CHẾ ATTENTION

GIẢNG VIÊN HƯỚNG DẪN: TS. VÕ THỊ HỒNG TUYẾT
SINH VIÊN THỰC HIỆN: Danh Hoàng Hiếu Nghị – 23DH112270

TP. HỒ CHÍ MINH – 07/2026

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ – TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



KHÓA LUẬN TỐT NGHIỆP

PHÂN ĐOẠN ẢNH TUYÊN TỤY TRÊN
CƠ CHẾ ATTENTION

GIẢNG VIÊN HƯỚNG DẪN: TS. VÕ THỊ HỒNG TUYẾT
SINH VIÊN THỰC HIỆN: Danh Hoàng Hiếu Nghị – 23DH112270

TP. HỒ CHÍ MINH – 07/2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày tháng năm 2026
Giảng viên hướng dẫn

TS. VÕ THỊ HỒNG TUYẾT

LỜI CẢM ƠN

Trong suốt quá trình thực hiện khóa luận tốt nghiệp, em đã nhận được sự hướng dẫn tận tình và những góp ý chuyên môn quý báu từ cô Võ Thị Hồng Tuyết. Cô đã giúp em định hình hướng nghiên cứu, chỉ ra những điểm chưa chặt chẽ trong cách đặt vấn đề và cách trình bày kết quả, đồng thời nhắc nhở em giữ thái độ thận trọng khi diễn giải số liệu thực nghiệm. Những trao đổi đó không chỉ giúp khóa luận hoàn thiện hơn về nội dung mà còn giúp em hiểu rõ hơn thế nào là một công việc nghiên cứu nghiêm túc.

Em xin gửi lời cảm ơn đến quý thầy cô Khoa Công nghệ thông tin, Trường Đại học Ngoại ngữ – Tin học Thành phố Hồ Chí Minh. Kiến thức nền tảng mà thầy cô truyền đạt trong những năm học vừa qua là cơ sở để em có thể tiếp cận một đề tài thuộc lĩnh vực học sâu và xử lý ảnh y khoa, vốn đòi hỏi kết hợp nhiều mảng kiến thức khác nhau.

Cuối cùng, em xin cảm ơn gia đình và bạn bè đã luôn ủng hộ, động viên em trong thời gian thực hiện khóa luận. Do giới hạn về thời gian, dữ liệu và tài nguyên tính toán, khóa luận chắc chắn còn nhiều thiếu sót. Em rất mong nhận được nhận xét và góp ý từ quý thầy cô để có thể tiếp tục hoàn thiện.

LỜI CAM ĐOAN

Em xin cam đoan khóa luận tốt nghiệp này là công trình do chính em thực hiện dưới sự hướng dẫn của cô Võ Thị Hồng Tuyết. Toàn bộ phần trình bày lý thuyết được em tự tổng hợp và diễn đạt lại từ các tài liệu tham khảo có nguồn gốc rõ ràng; mọi ý tưởng, kết quả hay phát biểu được kế thừa từ công trình của tác giả khác đều được trích dẫn đầy đủ trong phần Tài liệu tham khảo.

Phần cài đặt và thực nghiệm được em thực hiện trên bộ dữ liệu công khai Synapse. Các con số báo cáo trong khóa luận được lấy trực tiếp từ nhật ký thực nghiệm đã lưu lại của từng lần chạy, không chỉnh sửa và không suy đoán. Em cam đoan không sao chép nguyên văn từ bất kỳ nguồn nào và xin chịu hoàn toàn trách nhiệm về tính trung thực của nội dung khóa luận.

TP. Hồ Chí Minh, ngày tháng năm 2026

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

Danh Hoàng Hiếu Nghị

MỤC LỤC

LỜI CẢM ƠN	i
LỜI CAM ĐOAN	ii
MỤC LỤC.....	iii
DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ.....	v
DANH MỤC CÁC BẢNG.....	x
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ	xi
CHƯƠNG 1. MỞ ĐẦU	1
1.1 Lý do chọn đề tài.....	1
1.2 Mục tiêu, phạm vi và câu hỏi nghiên cứu.....	3
1.3 Đối tượng, phương pháp và đóng góp	4
1.4 Cấu trúc khóa luận	5
1.5 Tổng kết chương	6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU	7
2.1 Ảnh cắt lớp vi tính và đặc điểm dữ liệu y khoa	7
2.2 Bài toán phân đoạn ảnh y khoa	9
2.3 Tuyến tụy và các thách thức đặc thù.....	11
2.4 Mạng nơ-ron tích chập, FCN và học phần dư	12
2.5 U-Net và kiến trúc encoder-decoder	14
2.6 Cơ chế chú ý trong mạng tích chập: SE và CBAM	16
2.7 Transformer, self-attention và Vision Transformer	20
2.8 TransUNet: kiến trúc lai giữa CNN và Transformer	23
2.9 Reverse Attention và ý nghĩa trong vùng khó	25
2.10 Hàm mất mát cho bài toán phân đoạn.....	26
2.11 Các chỉ số đánh giá: Dice, Jaccard, HD95 và recall	28
2.12 Bộ dữ liệu Synapse và thiết lập đa cơ quan	32
2.13 Khoảng trống nghiên cứu và định hướng của khóa luận	34
2.14 Tổng kết chương	37
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT	39
3.1 Định nghĩa bài toán và nguồn truy vết.....	39
3.2 Pipeline TransUNet nền.....	40
3.3 CBAM trước patch embedding – cấu hình chính	42

3.4 CBAM đa tỷ lệ	47
3.5 Reverse Attention trên bộ giải mã	48
3.6 Các cấu hình được khảo sát	50
3.7 Chi phí, tính công bằng và khả năng tái lập.....	53
3.8 Tổng kết chương	53
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	55
4.1 Giới thiệu bộ dữ liệu	55
4.2 Cấu hình hệ thống và môi trường thực nghiệm	56
4.3 Giao thức huấn luyện và độ đo đánh giá	57
4.4 Kết quả và phân tích	59
4.5 So sánh với các công trình đã công bố	64
4.6 Khả năng tái lập và nguồn truy vết	65
4.7 Hạn chế của thực nghiệm.....	66
4.8 Tổng kết chương	67
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	68
5.1 Kết luận	68
5.2 Ưu điểm và nhược điểm của phương pháp đề xuất	69
5.3 Hướng phát triển	70
TÀI LIỆU THAM KHẢO.....	71
PHỤ LỤC.....	75
Phụ lục A. Tóm tắt tham số và nguồn truy vết	75
Phụ lục B. Ghi chú đọc kết quả	75

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ

Viết tắt / Thuật ngữ	Dạng đầy đủ tiếng Anh	Ý nghĩa tiếng Việt
Ablation study	Ablation study	Nghiên cứu loại bỏ, thay đổi một thành phần để đo ảnh hưởng
Attention	Attention mechanism	Cơ chế chú ý, cho phép mô hình phân bổ trọng số theo mức quan trọng
Backbone	Backbone	Mạng xương sống, phần trích xuất đặc trưng chính
Baseline	Baseline	Mô hình mốc dùng để so sánh
Batch size	Batch size	Số mẫu xử lý trong một bước cập nhật
Bottleneck	Bottleneck	Nút thắt cổ chai, tầng đặc trưng sâu nhất và nhỏ nhất
BTCV	Beyond the Cranial Vault	Tên thử thách gắn với bộ dữ liệu Synapse
CBAM	Convolutional Block Attention Module	Mô-đun chú ý kết hợp tuần tự theo kênh và theo không gian
Channel attention	Channel attention	Chú ý theo kênh, xác định kênh đặc trưng nào quan trọng
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập, học đặc trưng bằng bộ lọc cục bộ
Cross-entropy	Cross-entropy loss	Hàm mất mát entropy chéo, phạt sai lệch phân loại từng điểm ảnh
CT	Computed Tomography	Chụp cắt lớp vi tính, kỹ thuật dựng ảnh cắt lớp cơ thể bằng tia X
CUP	Cascaded Upsampler	Bộ giải mã tăng mẫu xếp tầng của TransUNet
Decoder	Decoder	Bộ giải mã, khôi phục

Viết tắt / Thuật ngữ	Dạng đầy đủ tiếng Anh	Ý nghĩa tiếng Việt
		độ phân giải để tạo mặt nạ
Dice	Dice Similarity Coefficient	Hệ số tương đồng Dice, đo độ trùng khớp giữa dự đoán và nhãn
Dice loss	Dice loss	Hàm mất mát dựa trên độ trùng khớp vùng
Encoder	Encoder	Bộ mã hóa, nén ảnh thành biểu diễn ngữ nghĩa
Epoch	Epoch	Một lượt duyệt hết tập huấn luyện
FCN	Fully Convolutional Network	Mạng tích chập toàn phần, dự đoán nhãn cho mọi điểm ảnh
Feature map	Feature map	Bản đồ đặc trưng, biểu diễn trung gian do mạng sinh ra
Fine-tuning	Fine-tuning	Tinh chỉnh mô hình đã tiền huấn luyện cho tác vụ đích
Ground truth	Ground truth	Nhãn tham chiếu do chuyên gia gán, dùng làm chuẩn đánh giá
HD95	95th percentile Hausdorff Distance	Phân vị thứ 95 của khoảng cách Hausdorff, đo sai lệch biên
Hidden feature	Hidden feature	Đặc trưng ẩn, bản đồ đặc trưng sâu nhất trước khi tạo token
HU	Hounsfield Unit	Đơn vị Hounsfield, thang đo mức hấp thụ tia X của mô
ImageNet-21k	ImageNet-21k	Tập ảnh lớn khoảng 21.000 lớp, dùng để tiền huấn luyện
Jaccard / IoU	Jaccard Index / Intersection over Union	Tỷ lệ giao trên hợp, thước đo trùng khớp chặt hơn Dice

Viết tắt / Thuật ngữ	Dạng đầy đủ tiếng Anh	Ý nghĩa tiếng Việt
Learning rate	Learning rate	Tốc độ học, bước cập nhật trọng số
LN	Layer Normalization	Chuẩn hóa theo lớp, ổn định quá trình huấn luyện
Mask	Segmentation mask	Mặt nạ phân đoạn, ảnh nhãn gán lớp cho từng điểm ảnh
MLP	Multi-Layer Perceptron	Mạng perceptron nhiều lớp
MSA	Multi-Head Self-Attention	Tự chú ý đa đầu, học nhiều kiểu quan hệ song song
Patch	Patch	Mảnh ảnh nhỏ, đơn vị đầu vào của Vision Transformer
Patch embedding	Patch embedding	Phép chiếu mảnh ảnh thành vector đặc trưng
Positional embedding	Positional embedding	Nhúng vị trí, bổ sung thông tin thứ tự cho token
Precision	Precision	Độ chính xác dương, tỷ lệ dự đoán dương là đúng
Pretrained	Pretrained weights	Trọng số tiền huấn luyện từ tập dữ liệu lớn
RA	Reverse Attention	Chú ý ngược, tập trung vào vùng mô hình đang bỏ sót
Recall	Recall / Sensitivity	Độ phủ, tỷ lệ vùng đối tượng thật được mô hình phát hiện
Receptive field	Receptive field	Trường tiếp nhận, vùng ảnh ảnh hưởng đến một vị trí đặc trưng
ResNet	Residual Network	Mạng phần dư, dùng kết nối tắt để huấn luyện mạng rất sâu
SE	Squeeze-and-Excitation	Mô-đun chú ý theo kênh

Viết tắt / Thuật ngữ	Dạng đầy đủ tiếng Anh	Ý nghĩa tiếng Việt
		dựa trên thông kê toàn cục
Self-attention	Self-attention	Tự chú ý, cho phép mọi phần tử trong chuỗi tương tác với nhau
SGD	Stochastic Gradient Descent	Hạ gradient ngẫu nhiên, thuật toán tối ưu
Skip connection	Skip connection	Đường nối tắt, truyền đặc trưng mức thấp sang bộ giải mã
Slice	Axial slice	Lát cắt ngang trục, một ảnh hai chiều trong khối CT
Spatial attention	Spatial attention	Chú ý theo không gian, xác định vị trí nào trên ảnh quan trọng
Synapse	Synapse Multi-Atlas Labeling	Bộ dữ liệu CT bụng đa cơ quan dùng làm chuẩn so sánh
Token	Token	Phần tử của chuỗi đầu vào Transformer
TP / FP / FN / TN	True/False Positive/Negative	Dương thật / dương giả / âm giả / âm thật
Transformer	Transformer	Kiến trúc dựa hoàn toàn trên cơ chế chú ý cho dữ liệu chuỗi
TransUNet	TransUNet	Kiến trúc lai dùng CNN trích đặc trưng, Transformer mô hình ngữ cảnh, decoder kiểu U-Net
U-Net	U-Net	Kiến trúc encoder-decoder đối xứng có đường nối tắt
ViT	Vision Transformer	Transformer áp dụng cho ảnh bằng cách chia ảnh thành mảnh
Volume	Volume	Khối ảnh ba chiều ghép từ nhiều lát cắt liên tiếp

Viết tắt / Thuật ngữ	Dạng đầy đủ tiếng Anh	Ý nghĩa tiếng Việt
Voxel	Volume element	Phần tử thể tích, tương đương điểm ảnh trong không gian ba chiều

DANH MỤC CÁC BẢNG

Bảng 2.1. Một số khái niệm nền tảng và vai trò của chúng trong khóa luận.....	9
Bảng 2.2. Các chỉ số đánh giá được sử dụng trong bài toán phân đoạn.	31
Bảng 2.3. Các lớp cơ quan trong thiết lập Synapse được sử dụng trong khóa luận.	34
Bảng 2.4. Ưu điểm, hạn chế và vấn đề còn tồn đọng của các nhóm mô hình phân đoạn ảnh y khoa liên quan.....	34
Bảng 3.1. Nguồn cài đặt dùng để truy vết phương pháp đề xuất.	39
Bảng 3.2. Luồng tensor chính của TransUNet nền trong thiết lập 224×224	40
Bảng 3.3. Năm cấu hình được khảo sát – TransUNet nền và bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối) – mô tả theo tham số dòng lệnh.	50
Bảng 3.4. Vị trí chèn mô-đun chú ý của bốn cấu hình theo trình tự các giai đoạn trong pipeline.	51
Bảng 3.5. Số tham số của năm cấu hình và mức chênh lệch so với TransUNet nền.	52
Bảng 4.1. Quy trình dữ liệu và hai đơn vị đếm được nêu tường minh.	56
Bảng 4.2. Thiết lập huấn luyện và đánh giá dùng chung cho các lần chạy.	57
Bảng 4.3. Kết quả phân đoạn tuyến tụy của TransUNet nền và bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối), kèm số tham số của từng cấu hình.	59
Bảng 4.4. Mức thay đổi của bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối) so với TransUNet nền.	59
Bảng 4.5. Kết quả theo từng cơ quan của cấu hình nền và cấu hình đề xuất. Giá trị $\Delta HD95$ mang dấu âm là có lợi.	62
Bảng 4.6. So sánh với các kết quả đã công bố trên bộ dữ liệu Synapse (cách chia chuẩn 18/12).	64
Bảng 4.7. Thành phần artifact phục vụ khả năng tái lập thực nghiệm.....	66
Bảng P.1. Tóm tắt tham số dòng lệnh và nguồn truy vết cho các cấu hình.	75

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 2.1. Sơ đồ chi tiết hai mô-đun chú ý thành phần của CBAM [9].	19
Hình 2.2. Cấu trúc thư mục dữ liệu Synapse trong thiết lập thực nghiệm.....	33
Hình 3.1. Luồng tổng quát của TransUNet nền dùng trong khóa luận.	41
Hình 3.2. CBAM dưới dạng một luồng tuần tự, kèm kết nối phần dư trước bước tạo token.	44
Hình 3.3. Kiến trúc CBAM-TransUNet đề xuất: khối CBAM phần dư tinh chỉnh bản đồ đặc trưng CNN ở tỷ lệ 1/16 ngay trước bước tạo token; bộ mã hóa Transformer và bộ giải mã giữ nguyên như cấu hình nền.	45
Hình 3.4. Vị trí khảo sát CBAM đa tỷ lệ trong pipeline TransUNet.	48
Hình 3.5. Reverse Attention trên nhánh skip 1/8 của decoder.....	49
Hình 3.6. Reverse Attention sau phép nối decoder-skip đầu tiên.	49
Hình 4.1. Bốn chỉ số tuyến tụy của năm cấu hình thực nghiệm. Cấu hình đặt CBAM trước bước tạo token là cấu hình duy nhất dẫn đầu đồng thời ở Dice và HD95.....	60
Hình 4.2. Minh họa kết quả phân đoạn định tính từ các cấu hình thực nghiệm.	64

CHƯƠNG 1. MỞ ĐẦU

1.1 Lý do chọn đề tài

Chẩn đoán hình ảnh đã trở thành một khâu không thể thiếu trong y học hiện đại. Trong số các kỹ thuật đang được dùng phổ biến, chụp cắt lớp vi tính (Computed Tomography – CT) [1] giữ vai trò đặc biệt quan trọng đối với vùng bụng, bởi nó cho phép quan sát đồng thời nhiều cơ quan trong cùng một lần chụp với độ phân giải không gian đủ tốt. Từ khối ảnh CT, bác sĩ có thể ước lượng kích thước cơ quan, phát hiện tổn thương, lập kế hoạch phẫu thuật hoặc theo dõi diễn tiến điều trị. Tuy nhiên, để những công việc đó được thực hiện một cách định lượng, trước hết cần xác định ranh giới của từng cơ quan trên ảnh – đây chính là bài toán phân đoạn ảnh y khoa.

Việc khoanh vùng cơ quan theo cách thủ công tiêu tốn rất nhiều thời gian. Một khối CT bụng thường gồm hàng trăm lát cắt, và chuyên gia phải xem xét từng lát để vẽ đường viền cho từng cơ quan. Công việc này không chỉ nặng nhọc mà còn phụ thuộc vào kinh nghiệm người thực hiện, dẫn tới sự khác biệt giữa các lần đo và giữa những người khác nhau. Đây cũng là lý do các phương pháp phân đoạn tự động dựa trên học sâu được quan tâm mạnh trong hơn một thập niên trở lại đây [2]. Nhu cầu về một phương pháp tự động, ổn định và có thể lặp lại vì thế là nhu cầu thực tế.

Trong nhóm các cơ quan vùng bụng, tuyến tụy (pancreas) được xem là một trong những đối tượng khó phân đoạn nhất. Khác với gan hay lách vốn có kích thước lớn và hình dạng tương đối ổn định, tuyến tụy nhỏ, nằm sâu, hình dạng thay đổi đáng kể giữa các bệnh nhân và có độ tương phản thấp so với mô mềm xung quanh. Trên nhiều lát cắt, ranh giới của tuyến tụy gần như hòa lẫn vào tá tràng, dạ dày hoặc mô mỡ lân cận. Hệ quả là ngay cả những mô hình học sâu đạt kết quả rất tốt trên các cơ quan lớn vẫn thường cho chỉ số thấp hẳn ở lớp tuyến tụy [3], [4]. Bên cạnh khó khăn kỹ thuật, tuyến tụy còn là nơi khởi phát của một trong những loại ung thư có tiên lượng xấu nhất, với số ca tử vong gần bằng số ca mắc mới trên phạm vi toàn cầu [5]; cho nên những công trình nghiên cứu tuyến tụy là vấn đề

được lưu tâm. Chính khoảng cách này khiến tuyến tụy trở thành một bài toán đáng để nghiên cứu riêng.

Về mặt kỹ thuật, các kiến trúc encoder-decoder mà tiêu biểu là U-Net [6] đã chứng minh hiệu quả trong phân đoạn ảnh y sinh nhờ khả năng giữ lại chi tiết mức thấp thông qua đường nối tắt. Tuy vậy, phép tích chập vốn mang bản chất cục bộ: mỗi bộ lọc chỉ nhìn thấy một vùng lân cận nhỏ, và để mô hình nắm được quan hệ giữa những vùng cách xa nhau thì cần xếp chồng rất nhiều tầng. Đối với một cơ quan nhỏ nằm giữa nhiều cấu trúc dễ gây nhầm lẫn như tuyến tụy, việc thiếu ngữ cảnh giải phẫu toàn cục là một bất lợi rõ rệt. Như vậy, cần một phương pháp giải quyết được đồng thời hai đòi hỏi tưởng như đối nghịch: vừa giữ được chi tiết cục bộ ở mức điểm ảnh, vừa nhìn được quan hệ giữa những vùng cách xa nhau trong ổ bụng.

Transformer xuất hiện như một lời giải cho hạn chế đó. Nhờ cơ chế tự chú ý [7], mọi phần tử trong chuỗi đầu vào đều có thể trao đổi thông tin trực tiếp với nhau, không phụ thuộc khoảng cách. TransUNet [8] là một trong những kiến trúc đầu tiên đưa ý tưởng này vào phân đoạn ảnh y khoa theo hướng lai: phần mạng tích chập vẫn đảm nhiệm trích xuất đặc trưng cục bộ, phần Transformer mô hình hóa ngữ cảnh toàn cục, còn bộ giải mã kiểu U-Net khôi phục độ phân giải. Cách kết hợp này tạo ra một điểm nổi rất đáng chú ý trong kiến trúc: ngay trước khi bản đồ đặc trưng của mạng tích chập bị cắt thành các token, nó vẫn còn giữ nguyên cấu trúc không gian hai chiều. Sau bước tạo token, biểu diễn trở thành một chuỗi và thông tin không gian chỉ còn được lưu giữ gián tiếp.

Quan sát trên gợi ra câu hỏi mà khóa luận muốn trả lời: nếu tinh chỉnh bản đồ đặc trưng ngay tại điểm nối đó – nghĩa là làm nổi bật những kênh và những vùng không gian có ích trước khi tạo token – thì chất lượng phân đoạn tuyến tụy có được cải thiện hay không? Mô-đun chú ý khối tích chập (Convolutional Block Attention Module – CBAM) [9] là một lựa chọn phù hợp cho mục đích này vì nó lần lượt áp dụng chú ý theo kênh rồi chú ý theo không gian, đồng thời giữ nguyên kích thước

của bản đồ đặc trưng đầu vào, nên có thể chèn vào mà không làm thay đổi phần còn lại của kiến trúc.

Điều đáng nói là CBAM không phải một mô-đun mới, và bản thân việc gắn thêm attention vào mạng phân đoạn cũng không mới. Vì vậy khóa luận không đặt mục tiêu phát minh một cơ chế chú ý khác, mà tập trung vào một câu hỏi hẹp hơn nhưng cụ thể hơn: vị trí đặt attention có ý nghĩa như thế nào? Để trả lời, khóa luận so sánh nhiều phương án đặt attention khác nhau trong cùng một điều kiện thực nghiệm, từ đó tách bạch ảnh hưởng của vị trí khỏi ảnh hưởng của những yếu tố khác như dữ liệu, ngân sách huấn luyện hay cách đánh giá.

1.2 Mục tiêu, phạm vi và câu hỏi nghiên cứu

Mục tiêu tổng quát của khóa luận là khảo sát ảnh hưởng của vị trí đặt mô-đun chú ý trong kiến trúc TransUNet đối với chất lượng phân đoạn tuyến tụy trên ảnh CT bụng. Mục tiêu này được cụ thể hóa thành ba nhiệm vụ. Thứ nhất, trình bày một cách có hệ thống các nền tảng lý thuyết liên quan, từ đặc điểm dữ liệu CT, bài toán phân đoạn, mạng tích chập, U-Net, cơ chế chú ý, Transformer cho tới kiến trúc TransUNet và các chỉ số đánh giá. Thứ hai, cài đặt cấu hình đề xuất trong đó một khối CBAM dạng phần dư được chèn vào ngay trước bước tạo token, cùng với các cấu hình đối chứng đặt attention ở những vị trí khác. Thứ ba, đánh giá và so sánh các cấu hình này trên cùng một giao thức thực nghiệm cố định, đồng thời phân tích kết quả theo cả tiêu chí trùng khớp vùng lẫn tiêu chí sai lệch biên.

Về phạm vi, khóa luận giới hạn ở bộ dữ liệu công khai Synapse (Multi-Atlas Labeling Beyond the Cranial Vault – BTCV) [10] với thiết lập chia dữ liệu quen thuộc gồm 18 ca huấn luyện và 12 ca kiểm thử, đúng theo cách chia mà TransUNet [8] và phần lớn các công trình đối chiếu sử dụng. Mô hình được huấn luyện theo từng lát cắt hai chiều và được đánh giá ở mức khối ba chiều. Mặc dù mô hình dự đoán đồng thời tám cơ quan cùng với nền, lớp tuyến tụy được chọn làm mục tiêu đánh giá chính; kết quả của các cơ quan còn lại chỉ được dùng để đặt kết quả tuyến tụy trong bối cảnh chung. Khóa luận không hướng tới việc thiết lập kỷ lục về hiệu

năng so với toàn bộ tài liệu đã công bố, bởi các nghiên cứu khác thường khác nhau về tiền xử lý, hậu xử lý hoặc cách huấn luyện; thay vào đó, khóa luận thực hiện một so sánh nội bộ trong cùng một giao thức để câu trả lời về vị trí đặt attention được diễn giải một cách công bằng.

Ba câu hỏi nghiên cứu được đặt ra như sau. Câu hỏi thứ nhất: việc tinh chỉnh bản đồ đặc trưng sâu nhất bằng CBAM ngay trước bước tạo token có cải thiện chỉ số phân đoạn tuyến tụy so với TransUNet nên hay không? Câu hỏi thứ hai: so với việc tinh chỉnh nhiều tầng đặc trưng nông hơn hoặc bổ sung chú ý ngược ở phía bộ giải mã, phương án đặt attention trước bước tạo token có ưu thế hay không? Câu hỏi thứ ba: khi xét đồng thời độ trùng khớp vùng và sai lệch biên, cấu hình nào cho hành vi cân bằng nhất, và điều đó nói lên điều gì về cách chọn mô hình?

1.3 Đối tượng, phương pháp và đóng góp

Đối tượng nghiên cứu của khóa luận là kiến trúc TransUNet [8] ở cấu hình lai R50-ViT-B/16, tức ghép mạng nền ResNet-50 [11] với Vision Transformer [12] và các biến thể có bổ sung mô-đun chú ý, áp dụng cho bài toán phân đoạn tuyến tụy trên ảnh CT bụng.

Phương pháp nghiên cứu kết hợp ba thành phần. Phần nghiên cứu lý thuyết tổng hợp và hệ thống hóa các kiến thức nền tảng cũng như các công trình liên quan, nhằm xác định rõ khoảng trống mà khóa luận hướng tới. Phần cài đặt thực nghiệm hiện thực hóa các cấu hình kiến trúc trên mã nguồn TransUNet, trong đó mô-đun CBAM được đặt tại những vị trí khác nhau tùy cấu hình. Phần đánh giá thực nghiệm huấn luyện toàn bộ các cấu hình dưới cùng một giao thức và so sánh chúng bằng bốn chỉ số bổ sung lẫn nhau.

Điểm cốt lõi trong cách tiếp cận là nguyên tắc so sánh có kiểm soát. Tất cả các cấu hình đều dùng chung một cách chia dữ liệu, một kích thước đầu vào, một họ mạng nền, một ngân sách huấn luyện, một hàm mất mát và một quy trình đánh giá. Khi các yếu tố này được giữ cố định, chênh lệch quan sát được giữa các cấu hình có

thể quy về sự khác biệt trong vị trí đặt attention thay vì về khác biệt trong điều kiện huấn luyện.

Từ đối tượng và phương pháp vừa nêu, có thể xác định rõ những gì khóa luận đóng góp. Về mặt học thuật, khóa luận có ba đóng góp chính. Thứ nhất, về mặt lý thuyết, khóa luận cung cấp một phần cơ sở lý thuyết được trình bày liền mạch, giải thích vì sao điểm nối giữa mạng tích chập và Transformer là một vị trí đáng quan tâm, thay vì chỉ liệt kê các kiến trúc một cách rời rạc. Thứ hai, về mặt phương pháp, khóa luận đề xuất và cài đặt cấu hình đặt CBAM dạng phần dư trước bước tạo token, kèm theo bốn cấu hình đối chứng cho phép tách bạch ảnh hưởng của vị trí. Thứ ba, về mặt thực nghiệm, khóa luận báo cáo kết quả tuyển tụy trên bốn chỉ số và chỉ ra rằng cấu hình đề xuất đạt đồng thời độ trùng khớp cao nhất và sai lệch biên thấp nhất, trong khi một số cấu hình khác chỉ cải thiện được một chỉ số riêng lẻ.

Bên cạnh ba đóng góp học thuật nêu trên, khóa luận còn có một số đóng góp mang tính thực tiễn. Thứ nhất, khối chú ý được đề xuất chỉ làm tăng khoảng 1,1 phần trăm số tham số và không thay đổi bất kỳ siêu tham số nào của phần còn lại, nên có thể ghép vào một hệ thống TransUNet đang vận hành mà không phải hiệu chỉnh lại quy trình huấn luyện hay hạ tầng tính toán. Thứ hai, toàn bộ mã nguồn, tệp cấu hình và nhật ký của từng lần chạy đều được lưu lại theo một cấu trúc thống nhất, nên mọi con số trong khóa luận có thể được kiểm chứng lại mà không cần huấn luyện lại từ đầu. Thứ ba, kết quả khảo sát vị trí cung cấp một chỉ dẫn thiết kế cụ thể cho những nhóm phát triển công cụ hỗ trợ khoanh vùng tuyển tụy: nên ưu tiên tinh chỉnh biểu diễn ngay trước bước tạo token thay vì bổ sung chú ý ở phía bộ giải mã, vì phương án sau có thể đẩy độ phủ lên cao nhưng làm đường viền xấu đi. Cần nói rõ rằng đây là các đóng góp ở mức nghiên cứu kỹ thuật trên dữ liệu công khai, chưa phải một sản phẩm đã được kiểm định lâm sàng.

1.4 Cấu trúc khóa luận

Khóa luận được tổ chức thành năm chương. Chương 1 giới thiệu bối cảnh, lý do chọn đề tài, mục tiêu, phạm vi, câu hỏi nghiên cứu và đóng góp. Chương 2 là

phần trọng tâm về mặt kiến thức nền, trình bày cơ sở lý thuyết và tổng quan nghiên cứu: đặc điểm ảnh CT, bài toán phân đoạn, những thách thức riêng của tuyến tụy, mạng tích chập và học phân dư, kiến trúc U-Net, các cơ chế chú ý trong mạng tích chập, Transformer và Vision Transformer, kiến trúc TransUNet, chú ý ngược, hàm mất mát, các chỉ số đánh giá, bộ dữ liệu Synapse, và cuối cùng là khoảng trống nghiên cứu. Chương 3 mô tả phương pháp đề xuất cùng các cấu hình được khảo sát. Chương 4 trình bày thiết lập thực nghiệm, kết quả định lượng, phân tích và những hạn chế. Chương 5 tổng kết và nêu hướng phát triển. Phần Tài liệu tham khảo và Phụ lục được đặt ở cuối.

1.5 Tổng kết chương

Chương 1 đã xác lập bối cảnh và ranh giới của khóa luận. Phân đoạn tuyến tụy trên ảnh CT bụng được chọn làm đề tài vì đây là cơ quan khó nhất trong nhóm cơ quan vùng bụng: thể tích nhỏ, tương phản thấp, hình dạng biến thiên mạnh giữa các bệnh nhân, và là nơi khởi phát của một loại ung thư có tiên lượng rất xấu. Trên nền TransUNet, chương đã chỉ ra điểm nổi giữa mạng tích chập và Transformer là một vị trí đáng quan tâm nhưng ít được khảo sát, và từ đó phát biểu ba câu hỏi nghiên cứu xoay quanh ảnh hưởng của vị trí đặt mô-đun chú ý.

Chương cũng đã khoanh vùng phạm vi – một bộ dữ liệu công khai, một cách chia chuẩn, một lớp mục tiêu là tuyến tụy – và nêu nguyên tắc xuyên suốt là so sánh có kiểm soát, trong đó mọi yếu tố ngoài vị trí attention đều được giữ cố định. Cuối cùng, chương đã liệt kê ba đóng góp học thuật và ba đóng góp thực tiễn mà khóa luận hướng tới.

Muốn trả lời được câu hỏi vị trí thì trước hết phải hiểu rõ từng thành phần trong kiến trúc lai và lý do tồn tại của chúng: vì sao cần đường nối tắt, vì sao cần cơ chế chú ý, vì sao cần Transformer, và bản đồ đặc trưng nào thực sự đứng ở điểm nổi. Chương 2 xây dựng nền lý thuyết đó theo đúng thứ tự vừa nêu.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

Chương này xây dựng nền tảng lý thuyết cho toàn bộ khóa luận. Trình tự trình bày đi từ bản chất dữ liệu đến bản chất bài toán, rồi mới đến các họ mô hình và công cụ đánh giá. Cách sắp xếp này nhằm bảo đảm rằng mỗi lựa chọn kỹ thuật ở Chương 3 đều có thể truy ngược về một lý do cụ thể đã được giải thích ở đây, thay vì được chấp nhận như một quy ước có sẵn.

2.1 Ảnh cắt lớp vi tính và đặc điểm dữ liệu y khoa

Chụp cắt lớp vi tính là kỹ thuật dựng lại hình ảnh bên trong cơ thể bằng cách chiếu tia X qua bệnh nhân từ nhiều góc khác nhau, sau đó dùng thuật toán tái tạo để suy ra mức hấp thụ tia tại từng vị trí [1]. Kết quả thu được không phải một ảnh đơn lẻ mà là một chuỗi lát cắt ngang trục xếp chồng lên nhau, tạo thành một khối ba chiều mô tả giải phẫu vùng được chụp [1]. Với vùng bụng, một khối như vậy thường chứa từ vài chục đến vài trăm lát cắt, mỗi lát là một ảnh hai chiều có độ phân giải phổ biến 512 x 512 điểm ảnh.

Giá trị của mỗi điểm ảnh trong ảnh CT được biểu diễn theo đơn vị Hounsfield [1], một thang đo được chuẩn hóa sao cho nước có giá trị bằng 0 và không khí có giá trị khoảng -1000. Đặc điểm này khiến ảnh CT khác biệt căn bản so với ảnh tự nhiên. Ở ảnh tự nhiên, cường độ điểm ảnh phụ thuộc vào ánh sáng và điều kiện chụp nên không mang ý nghĩa vật lý cố định. Ngược lại, giá trị Hounsfield phản ánh trực tiếp mật độ mô, nhờ đó cùng một loại mô sẽ nằm trong một dải giá trị tương đối ổn định giữa các bệnh nhân [1]. Tính chất này là một lợi thế: nó cho phép chuẩn hóa dữ liệu theo một dải giá trị có ý nghĩa lâm sàng thay vì chuẩn hóa tùy ý.

Tuy nhiên, lợi thế đó không tự động biến bài toán thành dễ. Vấn đề nằm ở chỗ nhiều cơ quan trong ổ bụng có mật độ mô rất gần nhau. Tuyến tụy, tá tràng, dạ dày và các quai ruột đều là mô mềm, nên dải Hounsfield của chúng chồng lấn đáng kể [3], [4]. Khi hai cấu trúc kề nhau có giá trị gần bằng nhau, ranh giới giữa chúng trên ảnh gần như biến mất, và không một ngưỡng cường độ nào có thể tách chúng ra một

cách đáng tin cậy. Đây là lý do cơ bản khiến các phương pháp dựa trên ngưỡng hoặc dựa trên biên cổ điển tỏ ra không đủ cho phân đoạn cơ quan bụng, và cũng là lý do các phương pháp học đặc trưng trở thành lựa chọn chủ đạo.

Một đặc điểm khác cần lưu ý là tính bất đẳng hướng của khoảng cách không gian. Trong mặt phẳng của một lát cắt, khoảng cách giữa hai điểm ảnh liền kề thường dưới một milimét, trong khi khoảng cách giữa hai lát cắt liên tiếp có thể lên tới vài milimét [4], [13]. Nói cách khác, độ phân giải theo chiều dọc thô hơn nhiều so với độ phân giải trong mặt phẳng. Hệ quả thực tế là một cơ quan mảnh như tuyến tụy có thể chỉ xuất hiện trên một số ít lát cắt, và hình dạng của nó thay đổi khá đột ngột giữa các lát kề nhau. Điều này ảnh hưởng trực tiếp đến cách đánh giá: các chỉ số đo khoảng cách biên phải được tính trong không gian ba chiều với khoảng cách vật lý thực, chứ không thể tính theo số điểm ảnh.

Dữ liệu y khoa còn có những ràng buộc mà dữ liệu ảnh thông thường không có. Số lượng ca có nhãn thường rất hạn chế, vì việc gán nhãn đòi hỏi chuyên gia và tốn nhiều thời gian. Một bộ dữ liệu CT bụng công khai với vài chục ca đã được xem là có giá trị [4], [13], trong khi các tập ảnh tự nhiên có thể chứa hàng triệu ảnh. Sự khan hiếm này dẫn tới hai hệ quả trong thiết kế thực nghiệm. Thứ nhất, việc tận dụng trọng số tiền huấn luyện từ tập dữ liệu lớn gần như là bắt buộc [2] nếu muốn huấn luyện các mô hình có nhiều tham số. Thứ hai, mọi so sánh giữa các mô hình đều phải được thực hiện trên cùng một cách chia dữ liệu, bởi chỉ cần thay đổi vài ca giữa tập huấn luyện và tập kiểm thử là con số báo cáo đã có thể dao động đáng kể.

Cuối cùng, nhãn trong phân đoạn đa cơ quan là nhãn không gian dạng loại trừ lẫn nhau: mỗi điểm ảnh được gán đúng một lớp, có thể là nền hoặc một trong các cơ quan [10]. Cách định nghĩa này biến bài toán thành phân loại từng điểm ảnh với số lớp bằng số cơ quan cộng thêm lớp nền, và nó cũng giải thích vì sao mất cân bằng nhãn là vấn đề cố hữu: phần lớn diện tích ảnh thuộc về nền, còn mỗi cơ quan chỉ chiếm một tỷ lệ nhỏ.

Những đặc điểm của dữ liệu vừa nêu quy định trực tiếp cách phát biểu bài toán phân đoạn, nội dung của mục tiếp theo.

2.2 Bài toán phân đoạn ảnh y khoa

Phân đoạn ảnh là bài toán gán cho mỗi điểm ảnh một nhãn lớp, qua đó chia ảnh thành những vùng có ý nghĩa. Nếu bài toán phân loại ảnh trả lời câu hỏi “trong ảnh có gì”, thì bài toán phân đoạn trả lời câu hỏi “vật thể đó nằm ở đâu và chiếm vùng nào”. Đầu ra vì thế không phải một nhãn duy nhất mà là một mặt nạ có cùng kích thước không gian với ảnh đầu vào [2], [14].

Về mặt hình thức, cho một lát cắt đầu vào $x \in \mathbb{R}^{H \times W}$ và tập nhãn $\{0, 1, \dots, K - 1\}$ với K là số lớp, mục tiêu là học một ánh xạ f_θ sao cho $f_\theta(x)$ tạo ra mặt nạ $\hat{y} \in \{0, \dots, K - 1\}^{H \times W}$ gần với nhãn tham chiếu y nhất có thể. Trên thực tế, mô hình không xuất trực tiếp nhãn rời rạc mà xuất một khối logits có kích thước $K \times H \times W$; nhãn cuối cùng thu được bằng cách lấy lớp có điểm số cao nhất tại mỗi vị trí. Cách làm này cho phép mô hình được huấn luyện bằng các hàm mất mát khả vi.

Bảng 2.1. Một số khái niệm nền tảng và vai trò của chúng trong khóa luận.

Khái niệm	Vai trò trong đề tài
Ảnh CT bụng	Dữ liệu đầu vào, chứa đồng thời nhiều cơ quan có mật độ mô gần nhau
Mask phân đoạn	Nhãn không gian gán một lớp cho từng điểm ảnh, dùng để huấn luyện và đánh giá
Feature map	Biểu diễn trung gian do mạng tích chập sinh ra, còn giữ cấu trúc không gian hai chiều
Patch token	Vector đặc trưng tạo từ một mảnh của bản đồ đặc trưng, là đơn vị đầu vào của Transformer
Skip connection	Đường truyền đặc trưng độ phân giải cao từ bộ mã hóa sang bộ giải mã để phục hồi chi tiết biên

Một mô hình phân đoạn tốt phải dung hòa hai yêu cầu vốn kéo về hai hướng ngược nhau. Hai yêu cầu này là sợi chỉ xuyên suốt mọi kiến trúc được điểm lại trong chương [2]. Yêu cầu thứ nhất là hiểu ngữ cảnh: để biết một vùng mô mềm là tuyến tụy chứ không phải tá tràng, mô hình cần dựa vào vị trí tương đối của vùng đó so với các mốc giải phẫu khác như cột sống, động mạch chủ hay lách. Thông tin

này mang tính toàn cục và thường nằm ở những đặc trưng có mức trừu tượng cao. Yêu cầu thứ hai là giữ chi tiết: để đường viền dự đoán bám sát đường viền thật, mô hình cần thông tin ở độ phân giải cao, vốn chỉ tồn tại ở các tầng nông. Khó khăn nằm ở chỗ quá trình nén đặc trưng để thu được ngữ cảnh cũng chính là quá trình làm mất chi tiết vị trí. Toàn bộ lịch sử phát triển của các kiến trúc phân đoạn, từ mạng tích chập toàn phần (Fully Convolutional Network – FCN) [14], U-Net [6] cho tới các mô hình lai gần đây [8], có thể được đọc như những cách khác nhau để hòa giải mâu thuẫn này.

Mất cân bằng nhãn là đặc trưng thứ hai của bài toán. Trên một lát cắt CT bụng, tuyến tụy nếu có mặt cũng chỉ chiếm một phần rất nhỏ diện tích, trong khi nền chiếm phần lớn [15]. Nếu chỉ tối ưu một hàm mất mát đếm lỗi trên từng điểm ảnh một cách đồng đều, mô hình có thể đạt tỷ lệ đúng rất cao bằng cách dự đoán gần như toàn bộ ảnh là nền, dù hoàn toàn vô dụng về mặt lâm sàng. Đây là lý do các hàm mất mát dựa trên độ trùng khớp vùng được đưa vào [15], và cũng là lý do chỉ số đánh giá phải được chọn cẩn thận.

Một đặc điểm nữa liên quan đến các lát cắt không chứa cơ quan cần tìm. Vì tuyến tụy chỉ xuất hiện trên một phần của khối CT, sẽ có nhiều lát cắt mà nhãn tham chiếu hoàn toàn trống. Khi mô hình dự đoán nhầm một vùng nhỏ trên những lát này, độ trùng khớp tại lát đó bằng không dù sai lệch tuyệt đối rất nhỏ. Cách xử lý những trường hợp biên như vậy phải được quy ước rõ ràng [16] và áp dụng thống nhất cho mọi cấu hình, nếu không việc so sánh sẽ mất ý nghĩa.

Cuối cùng, cần phân biệt hai mức thao tác: mức lát cắt và mức khối. Huấn luyện theo từng lát hai chiều giúp tăng số mẫu và giảm chi phí bộ nhớ, nhưng đánh giá thì cần thực hiện ở mức khối ba chiều [8], [16], bởi đại lượng mà bác sĩ quan tâm là toàn bộ cơ quan chứ không phải một lát riêng lẻ. Khóa luận này áp dụng đúng cách phân tách đó: tối ưu trên lát cắt, đánh giá trên khối.

Hai đặc điểm khó nhất của bài toán – ngữ cảnh xa và mất cân bằng nhãn – đều bộc lộ rõ nhất ở một cơ quan cụ thể. Mục sau phân tích cơ quan đó.

2.3 Tuyến tụy và các thách thức đặc thù

Tuyến tụy là một tuyến nằm sau phúc mạc, kéo dài ngang qua vùng bụng trên, thường được mô tả gồm ba phần là đầu, thân và đuôi. Về kích thước, tuyến tụy dài khoảng 15 centimet nhưng rất mảnh, nên thể tích của nó nhỏ hơn nhiều so với gan hay lách [3], [13]. Chính sự kết hợp giữa hình thái mảnh và thể tích nhỏ đã tạo ra một loạt khó khăn cho bài toán phân đoạn.

Khó khăn thứ nhất là độ tương phản thấp. Tuyến tụy tiếp giáp trực tiếp với tá tràng, dạ dày và mô mỡ xung quanh, tất cả đều là mô mềm có mật độ gần nhau [3]. Trên ảnh CT không tiêm thuốc cản quang hoặc ở những pha chụp mà thuốc chưa ngấm đủ, ranh giới giữa tuyến tụy và cấu trúc lân cận có thể mờ tới mức chuyên gia phải dựa vào kiến thức giải phẫu để suy luận chứ không thể nhìn thấy trực tiếp. Với mô hình học sâu, điều này có nghĩa là tín hiệu cường độ đơn thuần không đủ; mô hình buộc phải học mối quan hệ vị trí giữa tuyến tụy và các mốc giải phẫu ổn định hơn [3].

Khó khăn thứ hai là biến thiên hình dạng giữa các cá thể. Trong khi gan có hình dạng tương đối nhất quán, tuyến tụy thay đổi rõ rệt về độ cong, độ dày và hướng đi giữa những bệnh nhân khác nhau. Tuổi tác, thể trạng và bệnh lý đều ảnh hưởng đến hình thái của nó. Sự biến thiên này làm mô hình khó học được một khuôn mẫu hình dạng cố định, và cũng khiến kết quả trên tập kiểm thử dễ dao động giữa các ca [3], [13].

Khó khăn thứ ba là hệ quả trực tiếp của thể tích nhỏ. Với một cơ quan chỉ chiếm vài phần nghìn thể tích khối ảnh, một sai lệch tuyệt đối nhỏ về số điểm ảnh cũng đủ kéo chỉ số trùng khớp xuống đáng kể. Cùng một sai lệch dày một lớp điểm ảnh dọc theo đường viền sẽ gần như không ảnh hưởng đến hệ số Dice (Dice Similarity Coefficient) [16] của gan, nhưng lại có thể làm Dice của tuyến tụy giảm vài điểm phần trăm. Nói cách khác, tuyến tụy nhạy cảm hơn hẳn với sai số biên [16].

Những đặc điểm trên giải thích một hiện tượng thường thấy trong các báo cáo trên bộ dữ liệu CT bụng đa cơ quan: gan và lách thường đạt Dice trên 90 phần trăm, trong khi tuyến tụy hiếm khi vượt qua ngưỡng 60 phần trăm trong cùng một thiết lập [3], [4], [13]. Khoảng cách này không phản ánh sự yếu kém của mô hình nói chung, mà phản ánh độ khó nội tại của lớp tuyến tụy. Vì lý do đó, khóa luận chọn tuyến tụy làm mục tiêu đánh giá chính: đây là lớp mà một can thiệp kiến trúc có ích sẽ thể hiện tác dụng rõ nhất, đồng thời cũng là lớp mà mọi cải thiện đều có ý nghĩa thực tế.

Như vậy, khó khăn không nằm ở chỗ thiếu mô hình mạnh mà ở chỗ mô hình mạnh vẫn chưa nắm được đúng loại thông tin mà tuyến tụy đòi hỏi. Ba mục tiếp theo lần lượt điểm lại các họ mô hình theo đúng thứ tự chúng ra đời, để thấy mỗi thế hệ đã bù đắp thiếu sót nào của thế hệ trước.

2.4 Mạng nơ-ron tích chập, FCN và học phần dư

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là nền tảng của hầu hết các hệ thống thị giác máy tính hiện đại. Ý tưởng cốt lõi là thay vì kết nối mọi nơ-ron với mọi điểm ảnh, mạng chỉ dùng những bộ lọc nhỏ trượt trên toàn ảnh [2]. Cách làm này dựa trên hai giả định phù hợp với dữ liệu ảnh: tính cục bộ, tức là những điểm ảnh gần nhau có quan hệ chặt hơn những điểm ở xa; và tính bất biến tịnh tiến, tức là một mẫu hình có ý nghĩa như nhau dù xuất hiện ở đâu trên ảnh. Nhờ chia sẻ trọng số, số tham số giảm mạnh và mô hình học hiệu quả hơn nhiều so với mạng kết nối đầy đủ [2].

Khi các tầng tích chập được xếp chồng, mức trừu tượng của đặc trưng tăng dần. Những tầng đầu tiên phản ứng với biên và kết cấu đơn giản; các tầng sâu hơn tổ hợp chúng thành những mẫu hình phức tạp; các tầng sâu nhất mã hóa thông tin mang tính ngữ nghĩa như sự hiện diện của một cấu trúc giải phẫu. Song song với quá trình đó, các phép lấy mẫu xuống làm giảm dần độ phân giải không gian, đổi lại là mở rộng trường tiếp nhận – vùng ảnh đầu vào có ảnh hưởng đến một vị trí trên bản đồ đặc trưng [2], [14].

Mạng tích chập toàn phần (FCN) [14] đánh dấu bước chuyển quan trọng đưa mạng tích chập vào bài toán phân đoạn. Trước đó, các mạng phân loại kết thúc bằng những tầng kết nối đầy đủ, vốn phá vỡ cấu trúc không gian và chỉ cho ra một nhãn cho toàn ảnh. FCN thay các tầng đó bằng tầng tích chập, nhờ vậy đầu ra vẫn là một bản đồ hai chiều và mọi vị trí đều được gán nhãn trong một lần suy luận duy nhất [14]. Ý tưởng này biến phân đoạn thành bài toán dự đoán dày đặc và mở đường cho toàn bộ các kiến trúc encoder-decoder sau này.

Tuy nhiên, FCN bộc lộ một hạn chế rõ rệt: nếu chỉ lấy bản đồ đặc trưng ở tầng sâu nhất rồi phóng to trực tiếp lên độ phân giải gốc, kết quả sẽ rất thô. Nguyên nhân là thông tin vị trí chi tiết đã bị loại bỏ trong quá trình lấy mẫu xuống và không thể khôi phục bằng phép nội suy. Nhận thức này dẫn tới việc bổ sung các đường kết hợp đặc trưng từ tầng nông, và đó chính là tiền đề của U-Net [6].

Một mốc quan trọng khác là học phần dư. Về lý thuyết, mạng càng sâu càng có khả năng biểu diễn tốt hơn, nhưng trong thực tế các mạng rất sâu lại khó huấn luyện: gradient suy giảm khi lan truyền ngược qua nhiều tầng, khiến độ chính xác bão hòa rồi suy giảm [11]. Mạng phần dư (Residual Network – ResNet) [11] giải quyết vấn đề này bằng cách để mỗi khối học phần sai khác thay vì học trực tiếp ánh xạ đích. Nếu khối cần biểu diễn ánh xạ $H(x)$, mạng sẽ học phần dư $F(x) = H(x) - x$ và tính đầu ra theo công thức

$$H(x) = F(x) + x. \quad (2.1)$$

trong đó:

- x là đầu vào của khối phần dư;
- $H(x)$ là ánh xạ mà khối cần biểu diễn;
- $F(x)$ là phần dư – phần sai khác mà các tầng tích chập bên trong khối thực sự phải học.

Công thức có được bằng một phép biến đổi rất đơn giản: thay vì bắt khối học thẳng $H(x)$, ta viết $H(x) = F(x) + x$ rồi để khối chỉ học $F(x) = H(x) - x$. Hai vế hoàn toàn tương đương về mặt biểu diễn, nhưng bài toán tối ưu thì khác hẳn, vì trường

hợp “không cần thay đổi gì” tương ứng với $F(x) = 0$ – một nghiệm dễ đạt hơn nhiều so với việc học một ánh xạ đồng nhất.

Kết nối cộng thẳng đầu vào vào đầu ra mang lại hai lợi ích. Về mặt tối ưu, nó tạo một đường dẫn gradient trực tiếp xuyên qua khối, giúp tín hiệu học lan truyền tới các tầng đầu mà không bị suy giảm quá mức [11]. Về mặt biểu diễn, nếu phép biến đổi bổ sung không có ích, mạng chỉ cần đẩy $F(x)$ về gần 0 là khối trở thành ánh xạ đồng nhất, tức là mô hình không bị xấu đi so với khi không có khối đó. Đặc tính “không làm hỏng nếu không hữu ích” này chính là lý do khóa luận chọn dạng phần dư cho mô-đun chú ý được đề xuất ở Chương 3.

Trong khóa luận, mạng tích chập không bị thay thế mà được giữ lại đúng vai trò mà nó làm tốt nhất: trích xuất đặc trưng cục bộ ở nhiều mức độ phân giải. Cụ thể, một biến thể ResNet [11] đóng vai trò mạng nền theo đúng cấu hình của TransUNet [8], sinh ra các bản đồ đặc trưng ở các tỷ lệ 1/2, 1/4, 1/8 và 1/16 so với ảnh đầu vào. Ba tỷ lệ đầu được dùng làm đặc trưng nổi bật cho bộ giải mã, còn tỷ lệ 1/16 là bản đồ đặc trưng sâu nhất – chính là đối tượng mà can thiệp của khóa luận nhắm tới. Hạn chế cố hữu của tích chập, tức khả năng mô hình hóa quan hệ xa còn yếu, sẽ được bù đắp bởi thành phần Transformer trình bày ở mục 2.7.

Mạng tích chập giải quyết được việc trích xuất đặc trưng, nhưng chưa trả lời được câu hỏi làm sao khôi phục lại độ phân giải đã mất. Kiến trúc trình bày ở mục sau ra đời chính vì câu hỏi đó.

2.5 U-Net và kiến trúc encoder-decoder

U-Net [6] được thiết kế riêng cho phân đoạn ảnh y sinh và đã trở thành kiến trúc tham chiếu của lĩnh vực này. Tên gọi xuất phát từ hình dạng chữ U của sơ đồ kiến trúc: một nhánh đi xuống làm nhiệm vụ mã hóa, một nhánh đi lên làm nhiệm vụ giải mã, và giữa hai nhánh là các đường nối tắt bắc ngang.

Nhánh mã hóa hoạt động giống một mạng tích chập thông thường: các khối tích chập xen kẽ với phép lấy mẫu xuống, làm giảm dần độ phân giải và tăng dần số kênh cũng như mức trừu tượng. Nhánh giải mã đi theo chiều ngược lại: mỗi bước

tăng mẫu khôi phục một phần độ phân giải, và sau mỗi bước, đặc trưng được nối với đặc trưng tương ứng lấy từ nhánh mã hóa qua đường nối tắt [6]. Sự kết hợp này cho phép bộ giải mã sử dụng đồng thời hai nguồn thông tin: thông tin ngữ nghĩa mức cao đến từ tầng sâu, và thông tin vị trí mức thấp đến từ tầng nông [6].

Đường nối tắt chính là thành phần quyết định giá trị của U-Net. Nếu không có chúng, bộ giải mã chỉ có trong tay một bản đồ đặc trưng độ phân giải rất thấp và buộc phải “đoán” lại vị trí biên khi phóng to. Với ảnh y khoa, nơi sai lệch vài điểm ảnh dọc biên đã có thể làm thay đổi kết luận định lượng, việc mất chi tiết như vậy là không chấp nhận được. Đường nối tắt cho phép các chi tiết mức thấp đi thẳng tới nơi cần dùng mà không phải chịu tổn thất do nén [6], [17].

Một ưu điểm thực tế khác của U-Net là hiệu quả trên dữ liệu ít. Kiến trúc này được đề xuất trong bối cảnh dữ liệu y sinh có nhãn rất khan hiếm, và nó vẫn hoạt động tốt khi chỉ có vài chục ca huấn luyện [6], [18]. Đặc điểm đó lý giải vì sao U-Net và các biến thể của nó vẫn giữ vị trí trung tâm trong lĩnh vực này dù đã xuất hiện nhiều kiến trúc mới hơn.

Nhiều hướng cải tiến U-Net đã được đề xuất, và điều đáng chú ý là phần lớn chúng không thay đổi bộ trích xuất đặc trưng mà thay đổi cách thông tin được chọn lọc và hợp nhất. UNet++ [17] thiết kế lại các đường nối tắt thành một mạng lưới lồng nhau dày đặc nhằm thu hẹp khoảng cách ngữ nghĩa giữa đặc trưng của bộ mã hóa và bộ giải mã. Attention U-Net [19] chèn các cổng chú ý lên chính đường nối tắt, để đặc trưng nông được lọc bớt trước khi hợp nhất, nhờ đó những vùng không liên quan bị giảm trọng số. nnU-Net [18] thì đi theo hướng khác: thay vì đổi kiến trúc, nó tự động hóa việc cấu hình tiền xử lý, kích thước mẫu và siêu tham số theo đặc điểm dữ liệu, và chứng minh rằng một pipeline được cấu hình tốt có thể vượt nhiều kiến trúc phức tạp hơn. Ngoài ra, nhiều kiến trúc kết hợp Transformer cho ảnh y khoa cũng đã được đề xuất, như Medical Transformer [20], UNETR [21], Swin-Unet [22] và UCTransNet [23], trong khi SETR [24] cho thấy tiềm năng của Transformer trong phân đoạn ảnh tự nhiên.

Bài học rút ra từ nhóm công trình này rất quan trọng đối với khóa luận: chất lượng phân đoạn không chỉ phụ thuộc vào việc trích xuất đặc trưng gì, mà còn phụ thuộc vào việc chọn lọc và hợp nhất thông tin ở đâu. Nói cách khác, vị trí can thiệp là một biến thiết kế thực sự, chứ không phải chi tiết phụ [17], [19], [23]. Đây chính là tinh thần mà khóa luận kế thừa, chỉ khác ở chỗ vị trí được khảo sát nằm tại điểm nối giữa mạng tích chập và Transformer thay vì trên đường nối tắt như Attention U-Net.

TransUNet [8], kiến trúc nền của khóa luận, giữ lại đúng tinh thần U-Net ở phía giải mã: vẫn có bộ giải mã tăng mẫu nhiều bước và vẫn có các đường nối tắt lấy đặc trưng từ mạng tích chập. Điểm khác biệt nằm ở phần mã hóa, nơi một Transformer được đặt xen vào để bổ sung khả năng mô hình hóa ngữ cảnh toàn cục. Vì vậy, hiểu U-Net là điều kiện cần để hiểu vì sao TransUNet được thiết kế như hiện tại.

2.6 Cơ chế chú ý trong mạng tích chập: SE và CBAM

Trong mạng tích chập, mọi kênh đặc trưng và mọi vị trí không gian đều được đối xử như nhau: bộ lọc ở tầng sau tổ hợp chúng theo trọng số đã học, nhưng không có cơ chế nào cho phép mô hình điều chỉnh động mức đóng góp tùy theo từng đầu vào cụ thể. Cơ chế chú ý ra đời để lấp khoảng trống đó. Ý tưởng chung là học một tập trọng số phụ thuộc vào chính đầu vào, rồi nhân chúng vào bản đồ đặc trưng nhằm khuếch đại phần hữu ích và giảm bớt phần gây nhiễu [9], [25].

Mô-đun nén và kích thích (Squeeze-and-Excitation – SE) [25] là đại diện sớm và tinh gọn của hướng này, tập trung vào chiều kênh. Nó nén mỗi kênh thành một con số duy nhất bằng phép gộp trung bình toàn cục, cho một vector mô tả mức phản hồi tổng thể của từng kênh. Vector này đi qua một mạng nhỏ dạng nút thắt rồi qua hàm sigmoid để tạo ra trọng số trong khoảng từ 0 đến 1 cho mỗi kênh, cuối cùng được nhân trở lại vào bản đồ đặc trưng [25]. Kết quả là mô hình có thể tự quyết định, với từng ảnh cụ thể, những kênh nào đáng được ưu tiên. Điểm hạn chế là SE

hoàn toàn không phân biệt vị trí: nó nói được “kênh nào quan trọng” nhưng không nói được “vùng nào quan trọng”.

CBAM [9] mở rộng ý tưởng trên bằng cách bổ sung chiều không gian và áp dụng hai loại chú ý một cách tuần tự. Với bản đồ đặc trưng đầu vào F , bước thứ nhất tính chú ý theo kênh. Khác với SE vốn chỉ dùng gộp trung bình, CBAM dùng đồng thời gộp trung bình và gộp cực đại, cho hai vector mô tả bổ sung nhau: gộp trung bình phản ánh mức phản hồi tổng quát, còn gộp cực đại nhạy hơn với những phản hồi mạnh mang tính đặc trưng [9]. Hai vector cùng đi qua một mạng perceptron nhiều lớp có trọng số chia sẻ, được cộng lại rồi đưa qua hàm sigmoid:

$$M_c(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))). \quad (2.2)$$

trong đó:

- F là bản đồ đặc trưng đầu vào, kích thước $C \times H \times W$;
- $M_c(F)$ là bản đồ chú ý theo kênh, kích thước $C \times 1 \times 1$, mỗi phần tử nằm trong khoảng $(0, 1)$ và đóng vai trò trọng số cho một kênh;
- *AvgPool*, *MaxPool* là phép gộp trung bình và gộp cực đại toàn cục theo không gian, mỗi phép nén $C \times H \times W$ thành $C \times 1 \times 1$;
- *MLP* (Multi-Layer Perceptron) là mạng perceptron hai tầng dùng chung cho cả hai nhánh, có tỷ lệ nén $r = 16$ nên tầng ẩn chỉ còn $C/16$ nơ-ron;
- σ là hàm sigmoid, đưa kết quả về khoảng $(0, 1)$.

Công thức hình thành từ nhận xét rằng gộp trung bình và gộp cực đại mô tả hai khía cạnh bổ sung nhau của một kênh: gộp trung bình phản ánh mức phản hồi tổng quát, gộp cực đại nhạy với phản hồi mạnh mang tính đặc trưng. Vì vậy hai vector mô tả được đưa qua cùng một MLP rồi cộng lại trước khi qua sigmoid, thay vì chỉ dùng một phép gộp duy nhất như SE.

Bước thứ hai tính chú ý theo không gian trên bản đồ đặc trưng đã được hiệu chỉnh theo kênh. Lần này phép gộp được thực hiện dọc theo trục kênh, cho hai bản đồ hai chiều mô tả mức phản hồi tại từng vị trí. Hai bản đồ được ghép lại rồi đi qua

một tầng tích chập có nhân lớn để mô hình nắm được ngữ cảnh lân cận đủ rộng, sau đó qua hàm sigmoid [9]:

$$M_s(F) = \sigma(\text{Conv}_{7 \times 7}([\text{AvgPool}_c(F); \text{MaxPool}_c(F)])). \quad (2.3)$$


trong đó:

- $M_s(F)$ là bản đồ chú ý theo không gian, kích thước $1 \times H \times W$, mỗi phần tử là trọng số cho một vị trí;
- AvgPool_c , MaxPool_c là phép gộp trung bình và gộp cực đại dọc theo trục kênh, mỗi phép cho một bản đồ $1 \times H \times W$;
- $[;]$ là phép ghép hai bản đồ đó theo trục kênh, cho một tensor $2 \times H \times W$;
- $\text{Conv}^{7 \times 7}$ là một tầng tích chập nhân 7×7 đưa 2 kênh về 1 kênh; nhân lớn được chọn để mỗi vị trí quyết định dựa trên một vùng lân cận đủ rộng.

Công thức là bản đối ngẫu của công thức chú ý theo kênh: ở đó phép gộp chạy theo không gian để so sánh các kênh với nhau, còn ở đây phép gộp chạy theo kênh để so sánh các vị trí với nhau.

Hai bản đồ chú ý được áp dụng nối tiếp bằng phép nhân theo từng phần tử. Thứ tự kênh trước, không gian sau mang một ý nghĩa trực quan: mô hình quyết định “nên nhìn cái gì” trước, rồi mới quyết định “nên nhìn ở đâu” [9].

Hình 2.1 trình bày chi tiết cấu trúc bên trong của hai mô-đun thành phần. Nhánh chú ý theo kênh gộp bản đồ đặc trưng theo hai cách bổ sung cho nhau, đưa qua một mạng perceptron dùng chung rồi cộng hai kết quả lại trước khi qua hàm sigmoid. Nhánh chú ý theo không gian ghép hai bản đồ gộp dọc trục kênh và đưa qua một tầng tích chập để sinh trọng số cho từng vị trí [9].



Hình 2.1. Sơ đồ chi tiết hai mô-đun chủ yếu thành phần của CBAM [9].

Một tính chất của CBAM đặc biệt quan trọng đối với khóa luận: mô-đun này giữ nguyên kích thước của bản đồ đặc trưng. Đầu ra có đúng số kênh, đúng chiều cao và đúng chiều rộng như đầu vào [9]. Nhờ vậy, CBAM có thể được chèn vào giữa hai thành phần bất kỳ của một kiến trúc có sẵn mà không buộc phải thiết kế lại các phần xung quanh [9]. Đây chính là lý do CBAM phù hợp với vị trí mà khóa luận quan tâm – điểm nối ngay trước khi bản đồ đặc trưng bị chuyển thành chuỗi token.

Vị trí đặt CBAM ảnh hưởng trực tiếp tới loại thông tin mà nó tác động. Đặt ở tầng nông, mô-đun làm việc với đặc trưng còn mang nhiều biến thiên mức thấp như biên và kết cấu, nên tác dụng chọn lọc ngữ nghĩa còn hạn chế. Đặt ở tầng sâu nhất, mô-đun làm việc với đặc trưng đã giàu ngữ nghĩa nhưng vẫn còn cấu trúc không gian, nên chú ý theo kênh có cơ sở để chọn “đặc trưng của cơ quan nào”, đồng thời chú ý theo không gian vẫn còn lưới hai chiều để chỉ ra “vùng nào”. Đặt ở phía bộ giải mã, mô-đun chỉ tác động sau khi biểu diễn Transformer đã hình thành, nên nó tinh chỉnh quá trình tái tạo chứ không ảnh hưởng đến chất lượng của chuỗi token đầu vào. Ba khả năng này chính là ba nhóm cấu hình được khóa luận đưa vào khảo sát ở Chương 3. Việc chọn vị trí gắn cơ chế chú ý cũng chính là biến thiết kế mà Attention U-Net [19], UCTransNet [23] và FMD-TransUNet [26] khai thác, tuy mỗi công trình chọn một vị trí khác nhau.

Cần nhấn mạnh rằng khóa luận không trình bày CBAM như một mô-đun mới do mình đề xuất. CBAM là một thành phần đã được công bố [9] và sử dụng rộng

rãi. Đóng góp của khóa luận nằm ở câu hỏi đặt mô-đun đó ở đâu trong kiến trúc lai CNN-Transformer thì có lợi nhất cho lớp tuyến tụy, và ở việc trả lời câu hỏi đó bằng một thiết kế thực nghiệm có kiểm soát.

Chú ý theo kênh và theo không gian [9], [25] đều là những cơ chế chọn lọc gắn thêm vào mạng tích chập, nên vẫn bị giới hạn bởi tầm nhìn cục bộ của phép tích chập. Một họ mô hình khác giải quyết giới hạn đó ngay từ gốc, và đó là nội dung mục tiếp theo.

2.7 Transformer, self-attention và Vision Transformer

Transformer ban đầu được đề xuất cho dịch máy [7], nhằm thay thế các mạng hồi quy vốn xử lý chuỗi một cách tuần tự. Đóng góp then chốt của kiến trúc này là loại bỏ hoàn toàn tính tuần tự và thay bằng cơ chế tự chú ý, cho phép mọi phần tử trong chuỗi tương tác trực tiếp với mọi phần tử khác trong một bước duy nhất [7]. Nhờ đó, quan hệ giữa hai phần tử cách xa nhau không còn phải truyền qua nhiều bước trung gian như trong mạng hồi quy, cũng không cần xếp chồng nhiều tầng như trong mạng tích chập.

Cơ chế tự chú ý được xây dựng trên ba đại lượng dẫn xuất từ cùng một chuỗi đầu vào: truy vấn Q , khóa K và giá trị V , mỗi đại lượng là kết quả của một phép chiếu tuyến tính. Trọng số chú ý được tính bằng tích vô hướng giữa truy vấn và khóa, chuẩn hóa theo căn bậc hai của số chiều rồi đưa qua hàm softmax [7]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (2.4)$$

trong đó:

- Q, K, V lần lượt là ma trận truy vấn, khóa và giá trị, mỗi ma trận là kết quả của một phép chiếu tuyến tính từ cùng một chuỗi đầu vào;
- d_k là số chiều của một vector khóa;
- QK^T là ma trận điểm tương hợp: phần tử hàng i cột j đo mức phù hợp giữa truy vấn thứ i và khóa thứ j ;

– *softmax* chuẩn hóa mỗi hàng thành một phân phối xác suất, tổng bằng 1.

Hệ số chia cho căn bậc hai của số chiều khóa không phải quy ước tùy tiện. Nếu các thành phần của Q và K độc lập, có kỳ vọng 0 và phương sai 1 thì tích vô hướng của hai vector có phương sai bằng đúng số chiều đó; phép chia kéo phương sai về 1, nhờ đó softmax không rơi vào vùng bão hòa và gradient không bị triệt tiêu.

Về mặt trực giác, tích vô hướng đo mức tương hợp giữa một truy vấn và các khóa; softmax biến các mức tương hợp đó thành một phân phối trọng số; phép nhân với V tạo ra đầu ra là tổ hợp có trọng số của toàn bộ chuỗi. Việc chia cho $\sqrt{d_k}$ giữ cho tích vô hướng không quá lớn, tránh làm softmax bão hòa và gradient triệt tiêu [7].

Trên thực tế, cơ chế này được nhân bản thành nhiều đầu chạy song song, gọi là tự chú ý đa đầu (Multi-head Self-Attention – MSA). Mỗi đầu có phép chiếu riêng nên có thể học một kiểu quan hệ khác nhau; đầu ra của các đầu được ghép lại và chiếu về không gian ban đầu [7]. Mỗi khối Transformer gồm một tầng tự chú ý đa đầu và một mạng perceptron nhiều lớp (MLP), mỗi tầng đều được bọc bởi chuẩn hóa theo lớp (Layer Normalization – LN) và kết nối phần dư [7]:

$$z'_\ell = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}, \quad z_\ell = \text{MLP}(\text{LN}(z'_\ell)) + z'_\ell. \quad (2.5)$$

trong đó:

- z_ℓ là chuỗi token ở đầu ra của khối Transformer thứ ℓ ;
- MSA là tầng tự chú ý đa đầu (multi-head self-attention);
- MLP là mạng perceptron hai tầng áp dụng độc lập cho từng token;
- LN là phép chuẩn hóa theo lớp (layer normalization), đặt trước mỗi tầng con để ổn định phân phối đầu vào.

Cả hai dòng đều có dạng “đầu ra = tầng con(chuẩn hóa(đầu vào)) + đầu vào”, tức là đúng khuôn học phần dư của công thức (2.1) áp dụng hai lần liên tiếp.

Có thể thấy học phần dư trình bày ở mục 2.4 xuất hiện lại ở đây, cho thấy tính phổ quát của nguyên tắc [7], [11] “cộng thêm phần sai khác thay vì thay thế hoàn toàn”.

Vấn đề còn lại là làm sao ghép ưu điểm ngữ cảnh toàn cục của Transformer với ưu điểm giữ chi tiết của kiến trúc encoder-decoder. Kiến trúc lai trình bày ở mục sau chính là câu trả lời mà khóa luận lấy làm nền.

Vision Transformer (ViT) [12] là công trình đưa kiến trúc trên sang lĩnh vực thị giác. Trở ngại đầu tiên cần vượt qua là ảnh vốn là dữ liệu hai chiều chứ không phải chuỗi. Nếu xem mỗi điểm ảnh là một phần tử thì độ dài chuỗi trở nên khổng lồ, trong khi chi phí của tự chú ý tăng theo bình phương độ dài chuỗi. Giải pháp của ViT là chia ảnh thành các mảnh vuông không chồng lấn, làm phẳng từng mảnh rồi chiếu tuyến tính thành vector; mỗi mảnh khi đó trở thành một token [12]. Với ảnh 224×224 và mảnh kích thước 16×16 , số token là $(224/16)^2 = 196$, một độ dài chuỗi hoàn toàn khả thi.

Vì tự chú ý không mang thông tin thứ tự, ViT cộng thêm nhúng vị trí vào các token trước khi đưa vào chuỗi khối Transformer [12]. Nếu thiếu bước này, mô hình sẽ xem chuỗi token như một tập hợp không thứ tự và mất hoàn toàn thông tin bố cục không gian.

Điểm cần nhấn mạnh là ViT phải trả giá cho khả năng mô hình hóa toàn cục. Mạng tích chập mang sẵn những giả định phù hợp với ảnh – tính cục bộ và bất biến tịnh tiến – nên học hiệu quả ngay cả khi dữ liệu ít [12]. ViT gần như không mang giả định nào như vậy, do đó nó cần lượng dữ liệu rất lớn hoặc trọng số tiền huấn luyện từ tập dữ liệu lớn thì mới phát huy sức mạnh [2], [12]. Đây chính là lý do các mô hình dựa trên ViT trong ảnh y khoa hầu như luôn khởi tạo từ trọng số tiền huấn luyện, và cũng là lý do khóa luận sử dụng trọng số tiền huấn luyện trên ImageNet-21k cho mạng nền.

Một giới hạn khác của ViT thuần túy trong bài toán phân đoạn là mất chi tiết vị trí. Do toàn bộ quá trình xử lý diễn ra ở độ phân giải token, tức thấp hơn nhiều so

với ảnh gốc, việc phóng to trực tiếp đầu ra lên kích thước ban đầu cho kết quả thô, tương tự vấn đề mà FCN gặp phải. Điều này đã được chỉ ra ở SETR [24], công trình đầu tiên đưa Transformer thuần túy vào phân đoạn. Chính hạn chế này dẫn đến các kiến trúc lai, trong đó Transformer đảm nhận ngữ cảnh còn mạng tích chập cùng bộ giải mã đảm nhận chi tiết. TransUNet là đại diện tiêu biểu của hướng đi đó.

2.8 TransUNet: kiến trúc lai giữa CNN và Transformer

TransUNet [8], [27] được đề xuất nhằm kết hợp ưu điểm của hai họ mô hình: khả năng trích xuất đặc trưng cục bộ hiệu quả của mạng tích chập và khả năng mô hình hóa quan hệ xa của Transformer. Kiến trúc gồm ba thành phần chính, xếp nối tiếp nhau.

Thành phần thứ nhất là bộ mã hóa lai. Thay vì cắt token trực tiếp từ ảnh gốc như ViT, TransUNet cho ảnh đi qua một mạng tích chập nền trước, sau đó mới tạo token từ bản đồ đặc trưng thu được. Cách làm này có hai lợi ích. Một là chuỗi token ngắn hơn nhiều do bản đồ đặc trưng đã được thu nhỏ, giúp giảm chi phí tính toán. Hai là các bản đồ đặc trưng trung gian của mạng tích chập vẫn còn nguyên và có thể dùng làm đường nối tắt cho bộ giải mã [8]. Trong cấu hình được khóa luận sử dụng, mạng nền là một biến thể ResNet-50 kết hợp với ViT-B/16, thường được ký hiệu R50-ViT-B/16 [8], [11], [12].

Thành phần thứ hai là bộ mã hóa Transformer. Bản đồ đặc trưng sâu nhất, ở tỷ lệ 1/16 so với ảnh đầu vào, được chiếu thành các token và cộng thêm nhúng vị trí, rồi đi qua 12 khối Transformer [8]. Với ảnh đầu vào 224×224 , lưới đặc trưng ở tỷ lệ 1/16 có kích thước 14×14 , tương ứng 196 token, mỗi token có 768 chiều theo cấu hình cơ “Base”. Tại đây, mỗi token có thể trao đổi thông tin trực tiếp với mọi token khác, nhờ đó mô hình nắm được quan hệ giữa những vùng cách xa nhau trong lát cắt – đúng loại thông tin mà việc xác định tuyến tụy cần đến.

Thành phần thứ ba là bộ giải mã tăng mẫu xếp tầng, thường gọi tắt là CUP (Cascaded Upsampler) [8]. Chuỗi token đầu ra của Transformer được sắp xếp trở lại thành bản đồ hai chiều, sau đó đi qua bốn bước tăng mẫu liên tiếp, mỗi bước gồm

phép tăng mẫu hệ số 2 kèm tích chập và hàm kích hoạt. Tại ba bước đầu, đặc trưng được nối với các đặc trưng nối tắt lấy từ mạng tích chập ở các tỷ lệ $1/8$, $1/4$ và $1/2$ [8]. Cuối cùng, một đầu phân đoạn tạo ra bản đồ logits cho toàn bộ các lớp.

Điều đáng chú ý nhất đối với khóa luận nằm ở ranh giới giữa thành phần thứ nhất và thành phần thứ hai. Ngay trước bước tạo token, biểu diễn vẫn là một bản đồ đặc trưng bốn chiều có dạng $[B, C, H, W]$: nó vừa giàu ngữ nghĩa do đã đi qua toàn bộ mạng tích chập, vừa còn nguyên cấu trúc lưới hai chiều. Ngay sau bước tạo token, biểu diễn trở thành chuỗi có dạng $[B, N, D]$: quan hệ không gian chỉ còn được lưu giữ gián tiếp qua nhúng vị trí. Đây là ranh giới cuối cùng mà một mô-đun thao tác trên kênh và trên không gian như CBAM còn có thể hoạt động đúng bản chất của nó. Nếu chèn CBAM sau bước tạo token, khái niệm “chú ý theo không gian” không còn tương ứng với lưới ảnh nữa. Quan sát này, rút ra từ chính mô tả kiến trúc của công trình gốc [8], [27], là hạt nhân của toàn bộ khóa luận.

Cần nói thêm rằng bản thân nhóm tác giả TransUNet cũng đã nhận thấy vai trò của việc chọn vị trí can thiệp. Trong phần khảo sát của công trình gốc, các tác giả cho thấy số lượng đường nối tắt ảnh hưởng rõ rệt đến kết quả, và mức cải thiện thể hiện mạnh hơn ở các cơ quan nhỏ như tuyến tụy so với các cơ quan lớn. Họ cũng thử bổ sung Transformer nhẹ vào một nhánh nối tắt và ghi nhận cải thiện thêm [8], [27]. Những kết quả này củng cố giả thuyết rằng vị trí đưa thông tin vào và cách hợp nhất thông tin là biến thiết kế có ý nghĩa. Khóa luận tiếp nối hướng suy nghĩ đó, nhưng khảo sát một vị trí khác chưa được xem xét một cách hệ thống: bản đồ đặc trưng sâu nhất ngay trước bước tạo token.

Về mặt tổng quan, TransUNet là điểm gặp gỡ của ba mạch phát triển đã trình bày: mạch mạng tích chập cung cấp bộ trích xuất đặc trưng, mạch U-Net cung cấp bộ giải mã và đường nối tắt, mạch Transformer cung cấp khả năng mô hình hóa toàn cục [6], [7], [8], [14]. Vì vậy, khi khóa luận chọn TransUNet làm mô hình nền, lựa chọn đó không chỉ vì đây là một kiến trúc mạnh, mà còn vì nó là môi trường duy nhất trong ba mạch trên có tồn tại điểm nối CNN-Transformer cần khảo sát.

2.9 Reverse Attention và ý nghĩa trong vùng khó

Chú ý ngược là một cơ chế đi theo hướng bổ sung so với chú ý thông thường. Trong khi chú ý thông thường khuếch đại vùng mà mô hình đã tin là quan trọng, chú ý ngược tập trung vào phần bù: những vùng mà mô hình hiện đang cho điểm thấp, tức là những vùng có nguy cơ bị bỏ sót. Nếu A là bản đồ chú ý chuẩn hóa trong khoảng từ 0 đến 1, bản đồ chú ý ngược [28] đơn giản là $1 - A$.

Cơ chế này được đề xuất ban đầu trong phát hiện đối tượng nổi bật [28] và sau đó được áp dụng thành công cho phân đoạn polyp [29], nơi ranh giới giữa tổn thương và mô lành thường rất mờ. Lập luận đằng sau nó là: những vùng mô hình đã tự tin thì không cần tinh chỉnh thêm; giá trị gia tăng nằm ở những vùng mô hình còn do dự, thường chính là vùng biên [28]. Bằng cách buộc mạng chú ý vào phần bù, mô hình có cơ hội khôi phục những phần đối tượng bị bỏ sót và làm rõ đường viền.

Với tuyến tụy, đây là một ý tưởng có sức hấp dẫn rõ ràng. Như đã phân tích ở mục 2.3, phần lớn sai sót của mô hình đối với tuyến tụy tập trung ở vùng biên có độ tương phản thấp. Một cơ chế nhắm thẳng vào vùng chưa chắc chắn về nguyên tắc có thể giúp tăng độ phủ, đúng như hiệu quả đã được báo cáo trên bài toán phân đoạn polyp [29].

Tuy nhiên, chú ý ngược mang theo một rủi ro nội tại. Vì nó khuyến khích mô hình mở rộng dự đoán sang vùng đang bị cho điểm thấp, cơ chế này có xu hướng làm tăng độ phủ nhưng đồng thời cũng làm tăng dự đoán dương giả [28], [29]. Trong bối cảnh tuyến tụy tiếp giáp trực tiếp với những cấu trúc có mật độ mô tương tự, việc mở rộng sang vùng không chắc chắn hoàn toàn có thể lấn sang tá tràng hoặc dạ dày. Hệ quả là độ phủ tăng nhưng chất lượng biên xấu đi. Đây là lý do khóa luận không đánh giá các cấu hình chỉ bằng một chỉ số: một cấu hình có độ phủ cao nhất vẫn có thể là cấu hình có sai lệch biên tệ nhất, và kết quả thực nghiệm ở Chương 4 sẽ cho thấy đúng hiện tượng này.

Trong khóa luận, chú ý ngược được đưa vào với vai trò cấu hình đối chứng chứ không phải thành phần của mô hình đề xuất. Mục đích là kiểm tra xem tác động

lên phía bộ giải mã – tức là sau khi biểu diễn Transformer đã hình thành – có mang lại lợi ích tương đương hay vượt trội so với tác động trước bước tạo token hay không. Hai vị trí đặt chú ý ngược được khảo sát: trên nhánh nối tắt trước phép nối đầu tiên của bộ giải mã, và trên đặc trưng đã hợp nhất sau phép nối đó.

2.10 Hàm mất mát cho bài toán phân đoạn

Việc chọn hàm mất mát cho phân đoạn ảnh y khoa phải xuất phát từ đặc điểm mất cân bằng nhãn đã nêu ở mục 2.2. Hai họ hàm mất mát phổ biến giải quyết bài toán từ hai góc nhìn khác nhau, và trên thực tế chúng thường được dùng kết hợp [8], [15].

Họ thứ nhất là entropy chéo, xuất phát từ góc nhìn phân loại. Hàm này xem mỗi điểm ảnh là một mẫu phân loại độc lập và phạt theo logarit xác suất mà mô hình gán cho lớp đúng [14]:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} \log p_{i,k}, \quad (2.6)$$

trong đó:

- N là tổng số điểm ảnh của lát cắt;
- K là số lớp, ở đây bằng 9 gồm nền và tám cơ quan;
- $p_{i,k} \in (0, 1)$ là xác suất mô hình gán cho điểm ảnh thứ i thuộc lớp k , thu được sau hàm softmax;
- $y_{i,k} \in \{0, 1\}$ là nhãn tham chiếu dạng một-nóng: bằng 1 nếu điểm ảnh i thực sự thuộc lớp k và bằng 0 nếu ngược lại.

Công thức là ước lượng hợp lý cực đại viết dưới dạng cực tiểu hóa: xác suất mô hình gán đúng cho toàn ảnh là tích các xác suất tại lớp đúng của từng điểm ảnh; lấy logarit biến tích thành tổng, đổi dấu biến bài toán cực đại thành cực tiểu, và chia cho N để giá trị không phụ thuộc kích thước ảnh.

Ưu điểm của entropy chéo là cung cấp gradient ổn định cho mọi điểm ảnh. Nhược điểm là nó cộng đều đóng góp của từng điểm ảnh, nên khi nền chiếm đa số

áp đảo, tổng mất mát bị chi phối bởi nền và mô hình ít chịu áp lực phải dự đoán đúng cơ quan nhỏ [15].

Họ thứ hai là mất mát dựa trên độ trùng khớp vùng, mà tiêu biểu là Dice loss [15]. Hàm này xuất phát từ chính chỉ số đánh giá, xem xét toàn bộ vùng dự đoán và vùng nhãn như hai tập hợp và tối ưu trực tiếp mức trùng khớp giữa chúng:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i^2 + \sum_i g_i^2 + \epsilon}. \quad (2.7)$$

trong đó:

- $p_i \in (0, 1)$ là xác suất dự đoán tại điểm ảnh thứ i cho lớp đang xét;
- $g_i \in \{0, 1\}$ là giá trị nhãn tham chiếu tại chính điểm ảnh đó;
- ϵ là hằng số dương rất nhỏ, thêm vào cả tử và mẫu để tránh chia cho 0 khi cả vùng dự đoán lẫn vùng nhãn đều rỗng.

Công thức đi thẳng từ chỉ số Dice ở công thức (2.9). Tử số $2|P \cap G|$ được thay bằng hai lần tổng tích giữa giá trị dự đoán và giá trị nhãn tại từng điểm ảnh, còn mẫu số $|P| + |G|$ được thay bằng tổng bình phương của hai đại lượng đó: các tập hợp rời rạc được thay bằng tổng theo xác suất. Phép thay này giữ nguyên ý nghĩa nhưng làm hàm khả vi theo giá trị dự đoán nên có thể tối ưu bằng lan truyền ngược; cuối cùng lấy 1 trừ đi để biến một chỉ số “càng cao càng tốt” thành một hàm mất mát “càng thấp càng tốt”.

Vì Dice loss chuẩn hóa theo kích thước vùng, đóng góp của một cơ quan nhỏ không bị nền lấn át. Đây chính là tính chất mà bài toán tuyến tụy cần [15].

Trong khóa luận, hàm mất mát được dùng là tổ hợp tuyến tính của hai thành phần với trọng số bằng nhau, đúng theo thiết lập của TransUNet [8]:

$$\mathcal{L} = 0.5 \mathcal{L}_{\text{CE}} + 0.5 \mathcal{L}_{\text{Dice}}. \quad (2.8)$$

trong đó:

- L là hàm mất mát tổng dùng để cập nhật trọng số;
- $\mathcal{L}_{\text{CE}}$ là entropy chéo ở công thức (2.6);

- L_{Dice} là Dice loss ở công thức (2.7);
- 0,5 là trọng số của mỗi thành phần, được giữ nguyên cho toàn bộ các cấu hình để chênh lệch quan sát được không đến từ việc điều chỉnh hàm mất mát.

Trọng số bằng nhau được chọn theo đúng thiết lập của công trình TransUNet gốc [8], chứ không phải kết quả của một quá trình dò tìm siêu tham số; đây là một phần của nguyên tắc so sánh có kiểm soát.

Cách kết hợp này khai thác điểm mạnh của cả hai: entropy chéo giữ cho quá trình tối ưu ổn định ở giai đoạn đầu và cung cấp tín hiệu học cho mọi điểm ảnh, trong khi Dice loss bảo đảm rằng các lớp có thể tích nhỏ vẫn được quan tâm đúng mức [8], [15]. Quan trọng hơn, hàm mất mát này được giữ cố định cho toàn bộ các cấu hình trong khóa luận, để chênh lệch kết quả không thể bị quy cho sự khác biệt về mục tiêu tối ưu.

2.11 Các chỉ số đánh giá: Dice, Jaccard, HD95 và recall

Đánh giá phân đoạn không thể dựa vào một con số duy nhất, bởi mỗi chỉ số chỉ nắm bắt một khía cạnh của chất lượng. Khóa luận sử dụng bốn chỉ số bổ sung lẫn nhau, thuộc hai nhóm: nhóm đo độ trùng khớp vùng và nhóm đo sai lệch biên [16].

Hệ số Dice là chỉ số phổ biến nhất trong phân đoạn ảnh y khoa [15], [16]. Với tập dự đoán P và tập nhãn G , Dice được định nghĩa là

$$\text{Dice}(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (2.9)$$

trong đó:

- P là tập điểm ảnh mà mô hình dự đoán thuộc cơ quan đang xét;
- G là tập điểm ảnh thuộc cơ quan đó theo nhãn tham chiếu;
- $|P \cap G|$ là số điểm ảnh mà hai tập cùng chứa, tức số dương thật;
- $|P| + |G|$ là tổng lực lượng hai tập; giá trị Dice nằm trong khoảng từ 0 đến 1 và thường được báo cáo theo phần trăm.

Công thức xuất phát từ hệ số tương đồng Sørensen–Dice trong thống kê [16]: để so sánh hai tập hợp, ta lấy phần chung chia cho kích thước trung bình của chúng, tức $|P \cap G|$ chia cho $(|P| + |G|)/2$ – rút gọn lại đúng bằng biểu thức trên. Hệ số 2 ở tử số chính là hệ quả của việc lấy trung bình ở mẫu.

Có thể diễn giải Dice theo ngôn ngữ ma trận nhằm lần là $2TP/(2TP + FP + FN)$, tức là nó cân bằng giữa phần bỏ sót và phần thừa. Ưu điểm của Dice là ổn định và dễ so sánh giữa các công trình; hạn chế là nó chỉ đếm số điểm ảnh trùng khớp mà không quan tâm sai lệch nằm ở đâu [16].

Chỉ số Jaccard, còn gọi là tỷ lệ giao trên hợp (Intersection over Union – IoU), đo cùng khía cạnh nhưng nghiêm khắc hơn [16]:

$$\text{Jaccard}(P, G) = \frac{|P \cap G|}{|P \cup G|}. \quad (2.10)$$

trong đó:

- $|P \cap G|$ là số điểm ảnh nằm trong cả vùng dự đoán lẫn vùng nhãn;
- $|P \cup G|$ là số điểm ảnh nằm trong ít nhất một trong hai vùng, nên phần sai lệch chỉ được đếm một lần ở mẫu số.

So với Dice, khác biệt duy nhất là mẫu số dùng hợp thay vì tổng. Hai chỉ số quy đổi được cho nhau theo hệ thức $\text{Dice} = 2 \cdot \text{Jaccard} / (1 + \text{Jaccard})$, nên chúng luôn xếp hạng các mô hình giống nhau; tuy vậy Jaccard luôn nhỏ hơn hoặc bằng Dice và phạt sai lệch nặng hơn [16].

Nhóm chỉ số thứ hai đo sai lệch hình học của đường biên. Khoảng cách Hausdorff (Hausdorff Distance) đo khoảng cách lớn nhất từ một điểm trên bề mặt này tới bề mặt kia, nên nó rất nhạy với ngoại lai: chỉ cần một cụm dự đoán sai lẻ loi nằm xa cơ quan là chỉ số đã tăng vọt, dù phần lớn đường biên vẫn chính xác. Để giảm ảnh hưởng đó, thực tế sử dụng phân vị thứ 95 thay cho giá trị lớn nhất [16], ký hiệu HD95 (95th percentile Hausdorff Distance). Chỉ số này vẫn phản ánh sai lệch biên nhưng bỏ qua 5 phần trăm khoảng cách tệ nhất, nhờ vậy ổn định hơn mà không

đánh mất ý nghĩa. HD95 được tính theo đơn vị milimét trong không gian ba chiều và càng thấp càng tốt.

Ký hiệu ∂P và ∂G là bề mặt của vùng dự đoán và vùng nhãn tham chiếu, HD95 được viết gọn như sau:

$$HD95(P, G) = \max\{h95(\partial P, \partial G), h95(\partial G, \partial P)\} \quad (2.11)$$

trong đó:

- $\partial P, \partial G$ là tập các điểm nằm trên bề mặt vùng dự đoán và bề mặt vùng nhãn;
- $d(a, \partial B)$ là khoảng cách Euclid từ một điểm a tới điểm gần nhất trên bề mặt ∂B , tính trong không gian vật lý nên có đơn vị milimét;
- $h95(\partial A, \partial B)$ là phân vị thứ 95 của tập khoảng cách $\{d(a, \partial B) : a \in \partial A\}$, tức giá trị mà 95 phần trăm các điểm trên ∂A có khoảng cách nhỏ hơn hoặc bằng;
- $\max$ lấy giá trị lớn hơn giữa hai chiều đo, để chỉ số phạt cả trường hợp dự đoán thiếu lẫn trường hợp dự đoán thừa.

Công thức có được từ khoảng cách Hausdorff cổ điển [16] bằng đúng một thay đổi: thay phép lấy cực đại trên tập khoảng cách bằng phép lấy phân vị thứ 95. Khoảng cách Hausdorff gốc bị quyết định bởi một điểm tệ nhất duy nhất, nên chỉ một cụm dự đoán sai lẻ loi nằm xa cơ quan cũng đủ làm chỉ số tăng vọt; phân vị 95 bỏ qua 5 phần trăm khoảng cách tệ nhất nên ổn định hơn nhiều mà vẫn giữ nguyên ý nghĩa “đường viền nằm lệch bao nhiêu milimét”. HD95 càng thấp càng tốt.

Chỉ số thứ tư là recall (độ phủ, còn gọi là sensitivity) [16], đo tỷ lệ phần cơ quan thật được mô hình phát hiện:

$$\text{Recall} = \frac{TP}{TP+FN}. \quad (2.12)$$

trong đó:

- TP là số điểm ảnh thuộc cơ quan và được mô hình dự đoán đúng (dương thật);
- FN là số điểm ảnh thuộc cơ quan nhưng bị mô hình bỏ sót (âm giả);

- $TP + FN$ chính là toàn bộ số điểm ảnh của cơ quan theo nhãn tham chiếu, nên recall đo đúng tỷ lệ phần cơ quan được tìm thấy.

Công thức là định nghĩa trực tiếp từ ma trận nhầm lẫn [16] và có ý không chứa FP: recall chỉ trả lời câu hỏi “bỏ sót bao nhiêu”, còn câu hỏi “dự đoán thừa bao nhiêu” dành cho precision. Vì vậy recall một mình không đủ để kết luận, và trong khóa luận nó luôn được đọc kèm HD95.

Recall được đưa vào vì một lý do cụ thể: với tuyến tụy, kiểu lỗi đáng lo nhất thường là bỏ sót một phần cơ quan chứ không phải dự đoán thừa [3]. Một mô hình có thể có ít dương giả nhưng vẫn bỏ sót phần đuôi tụy, và Dice một mình không cho thấy rõ điều đó. Tuy nhiên, recall phải luôn được đọc cùng các chỉ số khác, bởi nó có thể được đẩy lên cao một cách giả tạo bằng cách dự đoán thừa: một mô hình dự đoán quá rộng sẽ có recall cao nhưng biên rất xấu.

Bảng 2.2. Các chỉ số đánh giá được sử dụng trong bài toán phân đoạn.

Chỉ số	Công thức / ý nghĩa	Chiều tốt
Dice	$2TP/(2TP + FP + FN)$, đo độ trùng khớp vùng giữa dự đoán và nhãn	Càng cao càng tốt
Jaccard / IoU	$TP/(TP + FP + FN)$, đo tỷ lệ giao trên hợp, nghiêm khắc hơn Dice	Càng cao càng tốt
HD95	Phân vị thứ 95 của khoảng cách biên hai chiều, tính bằng milimét	Càng thấp càng tốt
Recall	$TP/(TP + FN)$, đo tỷ lệ phần cơ quan thật được phát hiện	Càng cao càng tốt, nhưng phải đọc cùng HD95

Việc dùng đồng thời hai nhóm chỉ số là một lựa chọn có chủ đích. Hai chỉ số trùng khớp trả lời câu hỏi “mô hình có tìm đúng vùng cơ quan không”, còn HD95 trả lời câu hỏi “đường viền có nằm đúng chỗ không”. Một cấu hình chỉ tốt ở một nhóm không thể được xem là tốt hơn một cách toàn diện. Nguyên tắc này theo đúng khuyến nghị về việc phối hợp chỉ số vùng với chỉ số biên khi đánh giá phân đoạn ba

chiều [16]. Nguyên tắc chọn mô hình theo hành vi kết hợp, thay vì theo một chỉ số đơn lẻ, sẽ được áp dụng nhất quán ở Chương 4.


Đã có bài toán, mô hình, hàm mất mát và bộ chỉ số; phần còn thiếu là dữ liệu cụ thể để đo. Mục sau mô tả bộ dữ liệu được dùng xuyên suốt khóa luận.

Một quy ước cuối cùng cần nêu rõ: các chỉ số được tính ở mức khối ba chiều sau khi ghép dự đoán của từng lát cắt [8], [16], và với những ca mà nhãn tham chiếu không chứa tuyến tụy nhưng mô hình vẫn dự đoán có, Dice và Jaccard của ca đó được quy ước bằng 0. Quy ước này được áp dụng như nhau cho mọi cấu hình.

2.12 Bộ dữ liệu Synapse và thiết lập đa cơ quan

Khóa luận sử dụng bộ dữ liệu Synapse [10], gắn với thử thách gán nhãn đa bản đồ vùng bụng thường được nhắc tới dưới tên Beyond the Cranial Vault. Đây là một trong những bộ dữ liệu chuẩn được dùng rộng rãi nhất để so sánh các phương pháp phân đoạn CT bụng [10], và cũng chính là bộ dữ liệu mà TransUNet báo cáo kết quả, nên việc dùng nó giúp kết quả của khóa luận đặt được vào đúng bối cảnh so sánh.

Bộ dữ liệu gồm 30 ca chụp CT bụng đã được chuyên gia gán nhãn. Theo cách chia đã trở thành quy ước trong dòng công trình này, 18 ca được dùng để huấn luyện và 12 ca còn lại được dùng để kiểm thử [8], [10]. Khóa luận giữ nguyên cách chia đó thay vì tự chia lại, vì hai lý do. Thứ nhất, giữ nguyên cách chia giúp con số báo cáo có thể đối chiếu được với tài liệu đã công bố. Thứ hai, với một bộ dữ liệu chỉ 30 ca, mọi thay đổi trong cách chia đều có thể tạo ra dao động lớn, khiến việc so sánh mất ý nghĩa.



Hình 2.2. Cấu trúc thư mục dữ liệu Synapse trong thiết lập thực nghiệm.

Dữ liệu được tổ chức theo hai định dạng phục vụ hai mục đích khác nhau. Tập huấn luyện được lưu dưới dạng từng lát cắt riêng lẻ, mỗi lát là một tệp chứa ảnh và nhãn tương ứng; cách tổ chức này theo đúng quy ước của dòng công trình TransUNet [8] và phù hợp với việc huấn luyện theo lô các lát hai chiều. Tập kiểm thử được lưu theo từng khối, mỗi tệp chứa toàn bộ khối ảnh và khối nhãn của một ca; cách lưu này phục vụ việc đánh giá ở mức ba chiều, trong đó mô hình dự đoán tuần tự từng lát rồi ghép lại thành khối hoàn chỉnh trước khi tính chỉ số.

Cần phân biệt rõ hai đơn vị đếm khác nhau trong thiết lập này, vì chúng thường gây nhầm lẫn khi đối chiếu số liệu giữa các công trình. Con số 18 và 12 là số bệnh nhân, còn số mẫu huấn luyện thực tế là số lát cắt trích ra từ 18 ca đó: tổng cộng 2.211 lát cắt ngang, dao động từ 88 đến 195 lát mỗi ca với trung bình khoảng 122,8 lát. Ngược lại, giai đoạn kiểm thử không tách nhỏ như vậy mà giữ nguyên 12 khối ba chiều hoàn chỉnh. Như vậy cùng một bộ dữ liệu có thể được mô tả bằng “hơn hai nghìn mẫu” hoặc “ba mươi ca” tùy theo đơn vị đếm được chọn [8], [10].

Thiết lập phân đoạn gồm chín lớp: lớp nền và tám cơ quan vùng bụng [8], [10]. Mô hình dự đoán đồng thời cả chín lớp, nhưng khóa luận chỉ chọn lớp tuyến tụy làm mục tiêu đánh giá chính; kết quả của bảy cơ quan còn lại được dùng để đặt kết quả tuyến tụy vào bối cảnh chung và để kiểm tra xem can thiệp có gây tác dụng phụ ở nơi khác hay không.

Bảng 2.3. Các lớp cơ quan trong thiết lập Synapse được sử dụng trong khóa luận.

ID	Tên lớp (tiếng Anh)	Ý nghĩa tiếng Việt và ghi chú
0	background	Nền, không được tính là đối tượng cần phân đoạn
1	aorta	Động mạch chủ
2	gallbladder	Túi mật
3	left kidney	Thận trái
4	right kidney	Thận phải
5	liver	Gan
6	pancreas	Tuyến tụy, lớp trọng tâm của khóa luận
7	spleen	Lách
8	stomach	Dạ dày

Mọi lát cắt được đưa về kích thước 224×224 trước khi vào mạng. Vì mạng nền là một biến thể ResNet vốn được tiền huấn luyện trên ảnh ba kênh, lát cắt CT một kênh được lặp lại thành ba kênh để tương thích với trọng số tiền huấn luyện [8], [11]. Đây là một thao tác kỹ thuật đơn giản nhưng cần thiết, và nó cho thấy rõ ràng cái giá phải trả khi mượn trọng số từ miền ảnh tự nhiên sang miền ảnh y khoa.

2.13 Khoảng trống nghiên cứu và định hướng của khóa luận

Từ những nội dung đã trình bày, có thể tổng hợp bức tranh chung về các nhóm mô hình liên quan [2] như trong Bảng 2.4.

Bảng 2.4. Ưu điểm, hạn chế và vấn đề còn tồn đọng của các nhóm mô hình phân đoạn ảnh y khoa liên quan.

Nhóm mô hình	Ưu điểm	Hạn chế chính	Vấn đề còn tồn đọng
--------------	---------	---------------	---------------------

Nhóm mô hình	Ưu điểm	Hạn chế chính	Vấn đề còn tồn đọng
CNN / FCN	Học đặc trưng cục bộ hiệu quả, huấn luyện tốt với dữ liệu ít	Mô hình hóa quan hệ xa yếu, cần xếp chồng nhiều tầng	Không có cơ chế chọn lọc kênh và vị trí; mở rộng ngữ cảnh phải trả giá bằng độ sâu và số tham số
U-Net	Encoder-decoder cùng đường nối tắt giúp giữ chi tiết biên	Hiệu quả phụ thuộc cách chọn lọc và hợp nhất đặc trưng nối tắt	Cơ chế chọn lọc hầu như chỉ được gắn trên nhánh nối tắt, chưa xét các vị trí khác trong luồng
Transformer / ViT	Self-attention mô hình hóa ngữ cảnh toàn cục trong một bước	Cần dữ liệu lớn hoặc tiền huấn luyện; dễ mất chi tiết vị trí	Sau bước tạo token, cấu trúc lưới hai chiều biến mất nên chú ý theo không gian không còn áp dụng được
TransUNet	Kết hợp CNN, Transformer và bộ giải mã kiểu U-Net	Cần lựa chọn điểm tích hợp attention; điểm nối CNN-Transformer chưa được khai thác	Điểm nối ngay trước bước tạo token chưa được khảo sát như một vị trí can thiệp độc lập

Bức tranh này cho thấy một mạch phát triển nhất quán: mỗi thế hệ mô hình đều giải quyết một hạn chế của thế hệ trước, và phần lớn cải tiến gần đây không nằm ở việc phát minh khối tính toán mới mà nằm ở việc bố trí lại luồng thông tin. UNet++ [17] thay đổi cấu trúc đường nối tắt. Attention U-Net [19] thêm cổng chọn lọc lên đường nối tắt. TransUNet chèn Transformer vào giữa bộ mã hóa và bộ giải

mã. Trong cả ba trường hợp, câu hỏi được trả lời đều là “đặt cơ chế chọn lọc ở đâu”, chứ không phải “dùng cơ chế chọn lọc nào”.

Từ đó có thể nhận ra khoảng trống mà khóa luận hướng tới. Các công trình gắn attention vào kiến trúc lai CNN-Transformer thường tác động ở hai vùng: hoặc trên các nhánh nối tắt [19], [23], hoặc bên trong bộ giải mã [26], [29]. Trong khi đó, bản đồ đặc trưng sâu nhất – thứ nằm ngay trước bước tạo token – lại ít được xem xét như một vị trí can thiệp độc lập, mặc dù nó có một vị thế rất đặc biệt. Đây là biểu diễn cuối cùng còn hội đủ hai tính chất cùng lúc: đã đủ trừu tượng về mặt ngữ nghĩa, và vẫn còn nguyên cấu trúc lưới hai chiều. Sau bước tạo token, tính chất thứ hai biến mất.

Giả thuyết của khóa luận được phát biểu như sau: nếu tinh chỉnh bản đồ đặc trưng sâu nhất ngay trước bước tạo token, chuỗi token đưa vào Transformer sẽ mang tính phân biệt cao hơn, và điều đó có lợi cho một cơ quan nhỏ, ranh giới mờ như tuyến tụy. Giả thuyết này không được chấp nhận như một tiên đề mà được kiểm chứng bằng thực nghiệm, thông qua việc so sánh với những phương án đặt attention ở vị trí khác trong cùng một điều kiện.

Để kiểm chứng giả thuyết một cách có kiểm soát, khóa luận không khảo sát một phương án duy nhất mà xác định trước bốn hướng đặt mô-đun chú ý, trải dọc theo luồng xử lý của TransUNet từ phía bộ mã hóa sang phía bộ giải mã. Hướng thứ nhất là tinh chỉnh nhiều tầng đặc trưng nông ở các tỷ lệ 1/8, 1/4 và 1/2 rồi hợp nhất vào đặc trưng ẩn, đại diện cho quan niệm “can thiệp càng nhiều tầng càng tốt”. Hướng thứ hai là tinh chỉnh duy nhất đặc trưng ẩn ở tỷ lệ 1/16 ngay trước bước tạo token, tức chính giả thuyết vừa phát biểu. Hướng thứ ba là bổ sung chú ý ngược trên nhánh nối tắt 1/8, tức can thiệp sau khi biểu diễn Transformer đã hình thành nhưng trước khi hợp nhất với đặc trưng nối tắt. Hướng thứ tư là bổ sung chú ý ngược sau phép nối đầu tiên giữa đặc trưng giải mã và đặc trưng nối tắt, tức can thiệp sau khi hai luồng thông tin đã hòa vào nhau. Hai hướng đầu dựa trên CBAM [9], hai hướng sau dựa trên chú ý ngược [28], [29].

Bốn hướng này được chọn vì chúng phủ hết những vị trí có ý nghĩa khác nhau về bản chất biểu diễn trong pipeline, chứ không phải vì con số bốn. Hai hướng đầu nằm ở phía trước bước tạo token, nơi dữ liệu vẫn còn cấu trúc lưới hai chiều nên chú ý theo không gian còn có nghĩa hình học; chúng khác nhau ở chỗ can thiệp một tầng hay nhiều tầng. Hai hướng sau nằm ở phía sau, nơi thông tin đã đi qua Transformer; chúng khác nhau ở chỗ can thiệp trước hay sau khi hợp nhất. Cùng với cấu hình nền không có chú ý, bốn hướng tạo thành năm điểm quan sát đủ để trả lời câu hỏi vị trí mà không làm bùng nổ số lần huấn luyện. Cách bố trí này kế thừa tinh thần khảo sát vị trí của Attention U-Net [19] và UCTransNet [23], nhưng dịch điểm can thiệp về đúng ranh giới giữa mạng tích chập và Transformer [8].

Định hướng của khóa luận vì thế được xác lập rõ ràng. Về đối tượng, khóa luận không đề xuất mô-đun chú ý mới mà nghiên cứu vị trí đặt một mô-đun đã có. Về phương pháp, khóa luận dùng thiết kế so sánh có kiểm soát, cố định mọi yếu tố ngoài vị trí can thiệp. Về đánh giá, khóa luận dùng đồng thời chỉ số trùng khớp vùng và chỉ số sai lệch biên, và chỉ kết luận một cấu hình là tốt hơn khi nó thể hiện ưu thế trên cả hai khía cạnh. Chương 3 sẽ trình bày cụ thể cách hiện thực hóa định hướng này.

2.14 Tổng kết chương

Chương 2 đã dựng xong nền lý thuyết cho toàn bộ phần còn lại của khóa luận, theo một mạch đi từ dữ liệu tới công cụ đánh giá. Về dữ liệu, ảnh CT là khối ba chiều với giá trị điểm ảnh mang ý nghĩa vật lý theo đơn vị Hounsfield, có tính bất đẳng hướng về khoảng cách và luôn khan hiếm nhãn. Về bài toán, phân đoạn đa cơ quan là bài toán phân loại từng điểm ảnh với hai đặc trưng chi phối mọi lựa chọn kỹ thuật: đòi hỏi ngữ cảnh xa và mất cân bằng nhãn nghiêm trọng. Về đối tượng, tuyến tụy tập trung cùng lúc cả ba khó khăn – tương phản thấp, biến thiên hình dạng lớn và thể tích nhỏ.

Về mô hình, chương đã điểm lại bốn thể hệ theo đúng thứ tự chúng ra đời và chỉ ra rằng mỗi thể hệ giải quyết một hạn chế của thể hệ trước: mạng tích chập và

FCN đưa được phân đoạn về dạng đầu-cuối nhưng mất chi tiết vị trí; U-Net khôi phục chi tiết bằng đường nối tắt nhưng không có cơ chế chọn lọc; SE và CBAM bổ sung cơ chế chọn lọc theo kênh và theo không gian nhưng vẫn bị giới hạn bởi tầm nhìn cục bộ; Transformer và ViT phá bỏ giới hạn đó nhưng đánh mất cấu trúc lưới; TransUNet ghép hai phía lại với nhau. Về công cụ, chương đã trình bày hàm mất mát tổ hợp entropy chéo với Dice loss cùng bốn chỉ số đánh giá thuộc hai nhóm bổ sung nhau, và mô tả bộ dữ liệu Synapse dùng xuyên suốt.

Điểm quan trọng nhất rút ra từ phần tổng quan là khoảng trống nghiên cứu: các công trình gắn attention vào kiến trúc lai hầu như chỉ tác động trên nhánh nối tắt hoặc bên trong bộ giải mã, trong khi bản đồ đặc trưng ngay trước bước tạo token – biểu diễn cuối cùng còn hội đủ cả tính trừu tượng ngữ nghĩa lẫn cấu trúc lưới hai chiều – lại ít được xem xét như một vị trí can thiệp độc lập. Từ khoảng trống đó, chương đã phát biểu giả thuyết của khóa luận và xác định bốn hướng đặt attention sẽ được khảo sát. Chương 3 hiện thực hóa các hướng này thành những cấu hình kiến trúc cụ thể, mô tả từng phép biến đổi và ràng buộc bảo đảm tính công bằng khi so sánh.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Định nghĩa bài toán và nguồn truy vết

Bài toán được phát biểu như sau: cho một lát cắt CT bụng đã chuẩn hóa về kích thước 224×224 , cần dự đoán một mặt nạ gán cho mỗi điểm ảnh một trong chín lớp gồm nền và tám cơ quan. Mô hình được tối ưu ở mức lát cắt, còn chất lượng được đo ở mức khối ba chiều sau khi ghép dự đoán của các lát thuộc cùng một ca. Lớp tuyến tụy là mục tiêu đánh giá chính.

Để bảo đảm mọi phát biểu trong chương này đều có thể kiểm chứng, Bảng 3.1 liệt kê các tệp mã nguồn tương ứng với từng thành phần được mô tả. Việc gắn mô tả kiến trúc với vị trí cài đặt cụ thể giúp người đọc đối chiếu trực tiếp giữa lý thuyết và hiện thực, đồng thời giúp chính tác giả tránh mô tả sai những gì đã chạy.

Bảng 3.1. Nguồn cài đặt dùng để truy vết phương pháp đề xuất.

Nguồn	Vai trò
networks/vit_seg_modeling.py	Định nghĩa VisionTransformer, bộ giải mã và điểm chèn mô-đun chú ý
networks/vit_seg_modeling_resnet_skip.py	Tạo các bản đồ đặc trưng ResNet ở tỷ lệ 1/2, 1/4, 1/8 và đặc trưng ẩn 1/16
datasets/synapse.py	Đọc dữ liệu Synapse cho huấn luyện theo lát và kiểm thử theo khối
train.py	Thiết lập tham số huấn luyện, hàm mất mát và lịch trình học
test.py	Chạy suy luận, ghép khối, tính chỉ số và xuất kết quả
docs/results/run_registry.json	Nguồn số liệu cuối cùng cho các lần chạy được báo cáo

3.2 Pipeline TransUNet nền

Cấu hình nền được dùng làm mốc so sánh là TransUNet ở dạng lai R50-ViT-B/16, với mạng nền khởi tạo từ trọng số tiền huấn luyện trên ImageNet-21k, đúng theo cấu hình của công trình gốc [8], [27]. Luồng xử lý diễn ra theo bốn giai đoạn [8].

Giai đoạn thứ nhất là chuẩn bị đầu vào. Mỗi lát cắt CT một kênh được đưa về kích thước 224×224 rồi lặp thành ba kênh để tương thích với trọng số tiền huấn luyện của mạng nền [8], [12].

Giai đoạn thứ hai là trích xuất đặc trưng bằng mạng tích chập. Nhánh ResNet [11] sinh ra các bản đồ đặc trưng ở bốn mức độ phân giải. Ba mức nông hơn được giữ lại làm đặc trưng nổi tắt cho bộ giải mã [8], còn mức sâu nhất ở tỷ lệ 1/16 đóng vai trò đặc trưng ẩn. Với đầu vào 224×224 , đặc trưng ẩn có dạng $[B, 1024, 14, 14]$; số kênh 1024 là hệ quả trực tiếp của cấu hình ResNet được dùng, trong đó tầng sâu nhất có số kênh bằng 16 lần bề rộng cơ sở 64.


Giai đoạn thứ ba là mô hình hóa ngữ cảnh toàn cục. Đặc trưng ẩn được chiếu thành 196 token, mỗi token 768 chiều, cộng nhúng vị trí rồi đi qua 12 khối Transformer [7], [12].

Giai đoạn thứ tư là giải mã. Chuỗi token được sắp xếp lại thành bản đồ hai chiều và đi qua bốn bước tăng mẫu; ba bước đầu nối với đặc trưng nổi tắt ở các tỷ lệ 1/8, 1/4 và 1/2. Đầu phân đoạn cuối cùng tạo ra logits cho chín lớp ở độ phân giải gốc [6], [8].

Bảng 3.2. Luồng tensor chính của TransUNet nền trong thiết lập 224×224 .

Giai đoạn	Kích thước biểu diễn	Ý nghĩa
Input slice	$[B, 1, 224, 224]$	Lát cắt CT một kênh sau khi chuẩn hóa kích thước
Repeat channel	$[B, 3, 224, 224]$	Lặp kênh để phù hợp trọng số ResNet tiền huấn luyện
CNN 1/2	$[B, 64, 112, 112]$	Đặc trưng nổi tắt độ phân

Giai đoạn	Kích thước biểu diễn	Ý nghĩa
		giải cao
CNN 1/4	$[B, 256, 56, 56]$	Đặc trưng nổi bật trung gian
CNN 1/8	$[B, 512, 28, 28]$	Đặc trưng nổi bật đầu tiên của bộ giải mã
Hidden 1/16	$[B, 1024, 14, 14]$	Đặc trưng sâu nhất, ngay trước bước tạo token
Patch tokens	$[B, 196, 768]$	Chuỗi token đưa vào Transformer
Segmentation logits	$[B, 9, 224, 224]$	Logits cho nền và tám cơ quan



Hình 3.1. Luồng tổng quát của TransUNet nền dùng trong khóa luận.

Bảng 3.2 làm rõ điểm mấu chốt đã nêu ở mục 2.8. Dòng “Hidden 1/16” là dòng cuối cùng mà biểu diễn còn ở dạng bốn chiều với hai trục không gian rõ ràng; ngay dòng kế tiếp, biểu diễn đã trở thành chuỗi ba chiều. Ranh giới này là hệ quả trực tiếp của cách TransUNet ghép mạng tích chập với Transformer [8]. Toàn bộ can thiệp của khóa luận diễn ra chính xác tại ranh giới giữa hai dòng này.

Bảng 3.2 còn cho thấy hai chi tiết kỹ thuật đáng lưu ý. Thứ nhất, số kênh 1024 của đặc trưng ẩn không phải một con số tùy chọn [11] mà là hệ quả trực tiếp của cấu hình mạng nền: tầng sâu nhất của nhánh ResNet có số kênh bằng 16 lần bề rộng cơ sở, và với bề rộng cơ sở 64 thì kết quả đúng bằng 1024. Việc bám sát con số này

giúp mọi mô tả trong khóa luận khớp với những gì thực sự chạy trong mã nguồn, thay vì dựa trên sơ đồ minh họa vốn thường đơn giản hóa. Thứ hai, thao tác lặp lát cắt một kênh thành ba kênh là cái giá phải trả khi mượn trọng số tiền huấn luyện từ miền ảnh tự nhiên: mạng nền kỳ vọng đầu vào ba kênh, trong khi ảnh CT vốn chỉ có một kênh cường độ. Đây là một minh họa cụ thể cho ràng buộc đã nêu ở Chương 2 rằng dữ liệu y khoa khan hiếm buộc ta phải tận dụng trọng số từ miền khác, kèm theo những điều chỉnh kỹ thuật đi cùng.

3.3 CBAM trước patch embedding – cấu hình chính

Cấu hình đề xuất chèn một khối CBAM dạng phần dư vào đúng vị trí giữa đặc trưng ảnh và bước tạo token. Gọi F là đặc trưng ảnh, khối này thực hiện tuần tự ba phép toán theo đúng định nghĩa gốc của CBAM [9]:

$$F' = F \odot M_c(F), \quad F'' = F' \odot M_s(F'), \quad \hat{F} = F + F'', \quad (3.1)$$

trong đó:


- F là đặc trưng ảnh do bộ mã hóa lai sinh ra, kích thước $1024 \times 14 \times 14$;
- M_c, M_s là bản đồ chú ý theo kênh và theo không gian đã định nghĩa ở công thức (2.2) và (2.3);
- $\odot$ là phép nhân theo từng phần tử, có lan truyền chiều để một bản đồ $C \times 1 \times 1$ hoặc $1 \times H \times W$ nhân được với tensor $C \times H \times W$;
- F', F'' là đặc trưng sau khi lần lượt áp chú ý theo kênh và theo không gian;
- $\hat{F} = F + F''$ là đầu ra của khối, giữ nguyên kích thước $1024 \times 14 \times 14$ của F .

Ba bước được viết tách rời chứ không gộp thành một biểu thức [9] để thấy rõ thứ tự can thiệp: chọn kênh trước, chọn vị trí sau, rồi mới cộng phần dư. Bước cộng cuối cùng lặp lại đúng khuôn của công thức (2.1): nếu chú ý không có ích, mạng chỉ cần đẩy F'' về gần 0 là khối trở thành ánh xạ đồng nhất và cấu hình có CBAM không bị đặt vào thế bất lợi so với cấu hình nền. Hai siêu tham số bên trong được giữ đúng cấu hình gốc của CBAM: tỷ lệ nén $r = 16$ cho nhánh chú ý kênh và nhân tích chập 7×7 cho nhánh chú ý không gian.


Thành phần cộng phần dư ở bước cuối là một lựa chọn có chủ đích chứ không phải chỉ tiết trang trí. Nhờ nó, mô-đun chỉ học một lượng hiệu chỉnh cộng thêm vào đặc trưng gốc. Nếu cơ chế chú ý không mang lại lợi ích, mạng có thể đẩy F'' về gần 0 và khôi phục lại đúng đặc trưng ban đầu, nghĩa là cấu hình có CBAM không bị đặt vào thế bất lợi so với cấu hình nền. Đây chính là tinh thần của học phần dư đã trình bày ở mục 2.4, được áp dụng lại cho mô-đun chú ý [11].

Một tính chất quan trọng khác là bảo toàn hình dạng: $\hat{F}$ có đúng kích thước $[B, 1024, 14, 14]$ như F . Nhờ vậy, số token vẫn là 196, số chiều token vẫn là 768, số khối Transformer vẫn là 12, và toàn bộ bộ giải mã cùng các đường nối tắt được giữ nguyên. Tính bảo toàn hình dạng này là thuộc tính vốn có của CBAM [9]. Không một siêu tham số nào của phần còn lại bị thay đổi. Đây là điều kiện cần để có thể quy chênh lệch kết quả cho vị trí can thiệp thay vì cho việc mô hình có thêm dung lượng hay thay đổi cấu trúc.

Hình 3.2 mô tả toàn bộ khối dưới dạng một luồng tuần tự theo đúng trình tự kênh–không gian của CBAM [9]. Đặc trưng F đi qua chú ý theo kênh (A) để thành F' , tiếp tục qua chú ý theo không gian (B) để thành F'' , rồi được cộng với chính đặc trưng gốc thành $\hat{F} = F + F''$. Các mũi tên nét đứt biểu diễn đường dẫn phần dư đi vào phép nhân theo từng phần tử và phép cộng cuối cùng.



Hình 3.2. CBAM dưới dạng một luồng tuần tự, kèm kết nối phần dư trước bước tạo token.



Hình 3.3. Kiến trúc CBAM-TransUNet đề xuất: khối CBAM phân dư tính chỉnh bản đồ đặc trưng CNN ở tỷ lệ 1/16 ngay trước bước tạo token; bộ mã hóa Transformer và bộ giải mã giữ nguyên như cấu hình nền.

Lập luận đứng sau cấu hình này có thể tóm tắt như sau. Đặc trưng ẩn là biểu diễn đã đi qua toàn bộ mạng tích chập nên mang thông tin ngữ nghĩa mức cao, đồng thời vẫn giữ lưới nên chú ý theo không gian [9] còn có ý nghĩa hình học. Tinh chỉnh tại đây cho phép mô hình làm nổi bật những kênh liên quan tới tuyến tụy và những vùng có khả năng chứa cơ quan này, trước khi thông tin bị nén thành chuỗi token. Nếu chuỗi token đầu vào của Transformer mang tính phân biệt cao hơn, quá trình mô hình hóa ngữ cảnh toàn cục về nguyên tắc cũng thu được lợi ích, và cuối cùng bộ giải mã nhận được biểu diễn tốt hơn mà không cần thay đổi gì ở phía nó.

Một điểm mạnh thực tế của can thiệp này là chi phí rất thấp so với lợi ích. Khối CBAM chỉ thêm một mạng perceptron nhỏ cho nhánh chú ý kênh và một tầng

tích chập đơn cho nhánh chú ý không gian [9], nên số tham số tăng thêm là không đáng kể so với tổng số tham số của mạng nền cùng mười hai khối Transformer. Về mặt tính toán, mô-đun chỉ tác động một lần lên bản đồ đặc trưng 14×14 , tức ở độ phân giải thấp nhất trong toàn pipeline, nên thời gian suy luận gần như không đổi. Nói cách khác, cấu hình đề xuất theo đuổi cải thiện bằng cách bố trí lại luồng thông tin chứ không phải bằng cách tăng dung lượng mô hình, đúng với tinh thần đã trình bày ở Chương 2.

Con số cụ thể xác nhận nhận định trên. Mô hình nền có 105,28 triệu tham số, còn cấu hình đề xuất có 106,46 triệu, tức chỉ tăng 1,18 triệu tham số, tương đương khoảng 1,1 phần trăm. Ba cấu hình đối chứng còn lại cũng nằm trong biên độ tương tự, dao động từ 106,18 đến 107,59 triệu tham số. Nhờ khoảng cách hẹp này, mọi chênh lệch kết quả quan sát được ở Chương 4 khó có thể quy cho khác biệt về dung lượng mô hình.

Hai siêu tham số bên trong khối được giữ đúng theo cấu hình gốc của CBAM [9]. Tỷ lệ nén của mạng perceptron trong nhánh chú ý kênh được đặt bằng 16, đủ để giảm mạnh số tham số mà vẫn giữ khả năng biểu diễn quan hệ giữa các kênh. Tích chập trong nhánh chú ý không gian dùng nhân 7×7 thay vì nhân nhỏ hơn, vì bản đồ chú ý không gian cần một trường tiếp nhận đủ rộng để nắm được ngữ cảnh lân cận khi quyết định vùng nào nên được nhấn mạnh. Việc không tinh chỉnh riêng hai siêu tham số này cho từng cấu hình là có chủ đích, nhằm tránh đưa thêm một biến gây nhiễu vào phép so sánh.

Có thể đặt câu hỏi vì sao không đơn giản thêm attention vào bên trong các khối Transformer, vốn đã có sẵn cơ chế chú ý. Câu trả lời nằm ở bản chất biểu diễn: bên trong Transformer, dữ liệu đã là chuỗi token [12] và khái niệm chú ý theo không gian hai chiều không còn tương ứng với lưới ảnh. Chỉ tại đặc trưng ảnh, ngay trước bước tạo token, một mô-đun thao tác đồng thời trên kênh và trên lưới không gian như CBAM mới hoạt động đúng bản chất của nó. Đây là lý do vị trí này được chọn thay vì các vị trí thuận tiện hơn về mặt cài đặt.

3.4 CBAM đa tỷ lệ

Cấu hình đối chứng thứ nhất mở rộng phạm vi can thiệp sang các tầng nông hơn. Thay vì chỉ tinh chỉnh đặc trưng ẩn, biến thể này áp dụng CBAM [9] lên các đặc trưng ở tỷ lệ 1/8, 1/4 và 1/2, sau đó chiếu từng đặc trưng đã tinh chỉnh về không gian kênh của đặc trưng ẩn bằng một tích chập 1×1 kèm chuẩn hóa và hàm kích hoạt, thay đổi kích thước không gian về 14×14 khi cần, rồi hợp nhất vào đặc trưng ẩn thông qua một hệ số vô hướng học được:


$$h' = h + \alpha \cdot \text{Proj}_{1 \times 1}(\hat{F}). \quad (3.2)$$

trong đó:

- h là đặc trưng ẩn 1/16 trước khi hợp nhất;
- h' là đặc trưng ẩn sau khi hợp nhất, giữ nguyên kích thước của h ;
- F là đặc trưng nông đã được CBAM tinh chỉnh ở một tỷ lệ 1/8, 1/4 hoặc 1/2;
- $\text{Proj}^{1 \times 1}$ là tích chập nhân 1×1 kèm chuẩn hóa theo lô và hàm kích hoạt, đưa số kênh của F về đúng 1024 và đưa kích thước không gian về 14×14 khi cần;
- α là một hệ số vô hướng học được, khởi tạo bằng 0.

Dạng cộng có hệ số này cũng là một biến thể của công thức (2.1) [11]. Việc khởi tạo α bằng 0 khiến mô hình lúc bắt đầu huấn luyện hoàn toàn trùng với cấu hình nền, sau đó tự quyết định có nên mở nhánh hợp nhất hay không; nhờ vậy cấu hình đa tỷ lệ và cấu hình chính được so sánh trên cùng một điểm xuất phát.

Ngoài ra, biến thể này còn trả các đặc trưng đã tinh chỉnh về cho nhánh nối tắt của bộ giải mã, nên phạm vi ảnh hưởng của nó rộng hơn hẳn cấu hình chính, gần với cách UCTransNet [23] can thiệp trên toàn bộ các nhánh nối tắt.




Hình 3.4. Vị trí khảo sát CBAM đa tỷ lệ trong pipeline TransUNet.

Mục đích của cấu hình này là kiểm tra một giả định trực giác nhưng chưa chắc đúng: liệu can thiệp càng nhiều tầng thì kết quả càng tốt hay không. Nếu đúng, cấu hình đa tỷ lệ phải vượt cấu hình chỉ tinh chỉnh một tầng. Nếu không đúng, kết quả sẽ cho thấy rằng vị trí can thiệp quan trọng hơn số lượng vị trí được can thiệp.

3.5 Reverse Attention trên bộ giải mã


Hai cấu hình đối chứng còn lại chuyển hướng can thiệp sang phía bộ giải mã, dựa trên cơ chế chú ý ngược (Reverse Attention – RA) [28], [29] đã trình bày ở mục 2.9. Điểm cần lưu ý là cả hai đều giữ nguyên khối CBAM trước bước tạo token của cấu hình chính, rồi bổ sung thêm chú ý ngược ở phía sau. Nhờ thiết kế này, chênh lệch giữa chúng và cấu hình chính phản ánh đúng phần đóng góp thêm của chú ý ngược, chứ không lẫn với đóng góp của CBAM.

Cấu hình thứ nhất đặt chú ý ngược lên nhánh nối tắt ở tỷ lệ 1/8, tức là tác động lên đặc trưng nối tắt trước khi nó được nối vào bộ giải mã, tương tự cách chú ý ngược được gắn trong PraNet [29].



Hình 3.5. Reverse Attention trên nhánh skip 1/8 của decoder.

Cấu hình thứ hai đặt chú ý ngược sau phép nối đầu tiên giữa đặc trưng giải mã và đặc trưng nổi tắt, khi đó mô-đun nhận một tensor đã hợp nhất [28] có dạng $[B, 1024, 28, 28]$.



Hình 3.6. Reverse Attention sau phép nối decoder-skip đầu tiên.

Hai vị trí này đại diện cho hai thời điểm khác nhau trong quá trình tái tạo: trước khi hợp nhất và sau khi hợp nhất. Cùng với cấu hình chính và cấu hình đa tỷ

lệ, chúng tạo thành một dải vị trí trải từ trước bước tạo token cho tới sâu trong bộ giải mã, đủ để trả lời câu hỏi nghiên cứu về vai trò của vị trí.

3.6 Các cấu hình được khảo sát

Tổng cộng năm cấu hình được đưa vào so sánh, tóm tắt trong Bảng 3.3. Cột tham số dòng lệnh ghi lại đúng những tùy chọn được truyền cho mã nguồn khi chạy, nhờ vậy mỗi dòng trong bảng tương ứng với một lần chạy có thể tái lập.

Bảng 3.3. Năm cấu hình được khảo sát – TransUNet nền và bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối) – mô tả theo tham số dòng lệnh.

Cấu hình	Tham số dòng lệnh	Ý nghĩa
TransUNet nền	attention_mode = none; ra_mode = none	Mốc so sánh, không thêm CBAM hay chú ý ngược
Nhánh 1 – CBAM đa tỷ lệ	attention_mode = cnn_fusion; attention_scales = 1/8, 1/4, 1/2; ra_mode = none	Tinh chỉnh nhiều tầng nông rồi hợp nhất vào đặc trưng ẩn
Nhánh 2 – CBAM trước bước tạo token (đề xuất)	attention_mode = pre_hidden; attention_scales = 1/16; ra_mode = none	Cấu hình chính, chỉ tinh chỉnh đặc trưng ẩn trước bước tạo token
Nhánh 3 – CBAM + RA trên nhánh nối tắt	attention_mode = pre_hidden; attention_scales = 1/16; ra_mode = ra_skip	Giữ CBAM, thêm chú ý ngược trên nhánh nối tắt 1/8
Nhánh 4 – CBAM + RA sau phép nối	attention_mode = pre_hidden; attention_scales = 1/16; ra_mode = ra_fusion	Giữ CBAM, thêm chú ý ngược sau phép nối đầu tiên

Thiết kế này cho phép tách bạch ba yếu tố. So sánh dòng 1 với dòng 3 trả lời câu hỏi liệu can thiệp trước bước tạo token có ích hay không. So sánh dòng 2 với dòng 3 trả lời câu hỏi liệu mở rộng can thiệp ra nhiều tầng có tốt hơn hay không. So sánh dòng 3 với dòng 4 và dòng 5 trả lời câu hỏi liệu bổ sung chú ý ngược ở phía bộ giải mã có mang lại giá trị gia tăng hay không.

Cần nói rõ vì sao khảo sát dừng ở bốn nhánh chứ không nhiều hơn hay ít hơn. Bốn nhánh được chọn theo hai trục nhị phân chứ không theo cảm tính. Trục thứ nhất là thời điểm can thiệp so với bước tạo token: trước bước này dữ liệu vẫn là lưới hai chiều nên chú ý theo không gian còn ý nghĩa hình học, còn sau bước này dữ liệu đã là chuỗi token nên chỉ có thể can thiệp gián tiếp qua phía bộ giải mã. Trục thứ hai là phạm vi can thiệp trong mỗi nửa: ở nửa trước là một tầng hay nhiều tầng, ở nửa sau là trước hay sau khi hợp nhất hai luồng thông tin. Hai trục nhị phân cho đúng bốn tổ hợp, và bốn nhánh trong Bảng 3.3 phủ trọn bốn tổ hợp đó.

Thêm nhánh thứ năm sẽ không cung cấp thông tin mới về câu hỏi vị trí mà chỉ lặp lại một trong bốn tổ hợp ở một tỷ lệ khác, trong khi mỗi nhánh phải trả giá bằng một lần huấn luyện đầy đủ 150 vòng. Ngược lại, bỏ bớt một nhánh sẽ để trống một tổ hợp và làm kết luận về vị trí không còn đầy đủ. Như đã thấy ở Bảng 3.5, bốn nhánh này còn có số tham số rất gần nhau, nên chúng thỏa mãn điều kiện cần của một phép so sánh có kiểm soát: khác nhau ở vị trí can thiệp, gần như giống nhau ở mọi yếu tố còn lại.

Bảng 3.3 mô tả các cấu hình theo tham số dòng lệnh. Để thấy rõ điểm can thiệp nằm ở đâu trong luồng xử lý, Bảng 3.4 định vị lại từng cấu hình theo trình tự bảy giai đoạn của pipeline: (i) lát cắt đầu vào được nhân thành ba kênh; (ii) bộ mã hóa lai R50 sinh đặc trưng ẩn 1/16 kích thước $1024 \times 14 \times 14$ cùng các đặc trưng nổi tắt ở 1/8 (512 kênh), 1/4 (256 kênh) và 1/2 (64 kênh); (iii) bước tạo token chiều đặc trưng ẩn từ 1024 xuống 768 kênh và trải thành 196 token; (iv) mười hai khối Transformer áp dụng tự chú ý toàn cục; (v) chuỗi token được sắp lại và giảm về 512 kênh bằng một tầng tích chập 3×3 ; (vi) bộ giải mã CUP tăng mẫu và hợp nhất các đặc trưng nổi tắt; (vii) đầu phân đoạn sinh chín bản đồ lớp.

Bảng 3.4. Vị trí chèn mô-đun chú ý của bốn cấu hình theo trình tự các giai đoạn trong pipeline.

Cấu hình	Giai đoạn chèn	Các bước mới, theo thứ tự (mọi phần khác giữ nguyên như cấu hình nền)
Nhánh 1 – CBAM đa tỷ lệ	Trước bước tạo token; các tỷ lệ	CBAM phần dư trên từng đặc trưng nổi tắt nông; một cầu chiều 1×1 đưa mỗi đặc trưng

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

Cấu hình	Giai đoạn chèn	Các bước mới, theo thứ tự (mọi phần khác giữ nguyên như cấu hình nền)
	CNN 1/8, 1/4, 1/2	về 1024 kênh và đổi kích thước về 14×14 ; tổng có trọng số α được cộng vào F. Các đặc trưng đã tinh chỉnh cũng được trả về cho bộ giải mã.
Nhánh 2 – CBAM trước bước tạo token (đề xuất)	Trước bước tạo token; chỉ đặc trưng 1/16	CBAM phần dư trên F (kênh trước, không gian sau, giữ nguyên hình dạng); một cầu 1×1 ($1024 \rightarrow 1024$) và hệ số α học được; cộng phần dư $\hat{F} = F + \alpha \cdot \text{bridge}(\text{CBAM}(F))$. Các đặc trưng nối tắt giữ nguyên.
Nhánh 3 – CBAM + RA trên nhánh nối tắt	Trước tạo token 1/16, sau đó là nhánh nối tắt số 0 của bộ giải mã	Các bước của cấu hình (2); tiếp đó một khối chú ý ngược dạng nút thắt (hệ số nén 4) được áp lên nhánh nối tắt số 0 (tỷ lệ 1/8, 512 kênh) trước khi nó được nối vào.
Nhánh 4 – CBAM + RA sau phép nối	Trước tạo token 1/16, sau đó là khối giải mã số 0	Các bước của cấu hình (2); tiếp đó chú ý ngược được áp lên đặc trưng đã nối (512 kênh giải mã + 512 kênh nối tắt = 1024 kênh) bên trong khối giải mã số 0.

Một câu hỏi tự nhiên là liệu chênh lệch kết quả giữa các nhánh có đơn thuần đến từ việc nhánh nào nhiều tham số hơn hay không. Bảng 3.5 trả lời câu hỏi đó bằng số liệu đếm trực tiếp trên mô hình đã dựng.

Bảng 3.5. Số tham số của năm cấu hình và mức chênh lệch so với TransUNet nền.

Cấu hình	Tham số (triệu)	Chênh lệch (triệu)	Chênh lệch (%)
TransUNet nền	105,28	–	–
Nhánh 1 – CBAM đa tỷ lệ	106,18	+0,90	+0,86
Nhánh 2 – CBAM trước bước tạo token (đề xuất)	106,46	+1,18	+1,12
Nhánh 3 – CBAM + RA trên nhánh nối tắt	106,74	+1,46	+1,39
Nhánh 4 – CBAM + RA sau phép nối	107,59	+2,31	+2,19

Ba nhận xét rút ra từ bảng này. Thứ nhất, toàn bộ bốn nhánh đề xuất đều nằm trong khoảng 106,18 đến 107,59 triệu tham số, tức chỉ hơn cấu hình nền từ 0,86 đến 2,19 phần trăm; phần lõi 105,28 triệu tham số gồm mạng nền ResNet-50, mười hai khối Transformer và bộ giải mã là chung cho mọi cấu hình. Thứ hai, nhánh được đề

xuất không phải nhánh nặng nhất mà chỉ đứng thứ ba về số tham số, thêm 1,18 triệu tham số so với nền. Thứ ba, khoảng cách giữa nhánh nhẹ nhất và nhánh nặng nhất chỉ là 1,41 triệu tham số, nhỏ hơn nhiều so với mức chênh lệch kết quả sẽ trình bày ở Chương 4. Nhờ khoảng cách hẹp này, chênh lệch quan sát được có thể quy về vị trí đặt mô-đun chú ý thay vì quy về dung lượng mô hình.

3.7 Chi phí, tính công bằng và khả năng tái lập

Toàn bộ năm cấu hình được xây dựng trên cùng một khung mã nguồn, chỉ khác nhau ở một vài tùy chọn quyết định vị trí và kiểu can thiệp, như đã tóm tắt trong Bảng 3.3. Cách thiết kế này bảo đảm rằng khi so sánh, mọi khác biệt về dữ liệu, mạng nền, số token, số khối Transformer hay bộ giải mã đều bằng không. Nhờ vậy, chênh lệch kết quả có thể được quy về đúng biến mà khóa luận muốn khảo sát là vị trí đặt attention, thay vì bị lẫn với những khác biệt ngoài ý muốn.

Để kết quả có thể kiểm chứng, mỗi cấu hình được gắn với một tập tệp cài đặt cụ thể và một lần chạy có định danh riêng. Hạt giống ngẫu nhiên được cố định, các tham số dòng lệnh được ghi lại, và toàn bộ chỉ số cuối cùng được đọc trực tiếp từ tệp kết quả của lần chạy tương ứng chứ không nhập thủ công. Phụ lục A liệt kê ảnh xạ giữa từng cấu hình với notebook và thiết lập đã dùng, cho phép người đọc lần ngược mỗi con số về đúng nguồn sinh ra nó.

3.8 Tổng kết chương

Chương 3 đã chuyển giả thuyết của Chương 2 thành những cấu hình kiến trúc cụ thể và có thể chạy được. Xuất phát điểm là pipeline TransUNet nền, trong đó đặc trưng ảnh kích thước $1024 \times 14 \times 14$ là biểu diễn cuối cùng còn giữ cấu trúc lưới trước khi bị chuyển thành 196 token. Cấu hình được đề xuất chèn đúng một khối CBAM dạng phần dư vào vị trí đó; nhờ khối này bảo toàn hình dạng tensor, số token, số chiều token, số khối Transformer, bộ giải mã và toàn bộ các đường nối tắt đều không đổi.

Bên cạnh cấu hình chính, chương đã mô tả ba nhánh đối chứng: hợp nhất CBAM đa tỷ lệ từ các tầng nông, chú ý ngược trên nhánh nối tắt 1/8, và chú ý ngược sau phép nối đầu tiên. Bảng 3.3 định vị bốn nhánh theo tham số dòng lệnh, Bảng 3.4 định vị chúng theo trình tự bảy giai đoạn của pipeline, còn Bảng 3.5 cho thấy cả bốn chỉ nặng hơn cấu hình nền từ 0,86 đến 2,19 phần trăm số tham số. Ba bảng này cùng chứng minh rằng biến duy nhất thay đổi giữa các nhánh là vị trí can thiệp.

Cuối cùng, chương đã nêu các ràng buộc bảo đảm tính công bằng và khả năng tái lập: chung một khung mã nguồn, chung một hạt giống ngẫu nhiên, chung một tập tham số huấn luyện, và mọi chỉ số đều đọc trực tiếp từ tệp kết quả của lần chạy tương ứng. Với thiết kế đó, mọi chênh lệch đo được ở Chương 4 đều có thể quy về vị trí đặt mô-đun chú ý.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Giới thiệu bộ dữ liệu

Toàn bộ thực nghiệm của khóa luận được tiến hành trên bộ dữ liệu công khai Synapse multi-organ CT, còn được biết đến với tên gọi Multi-Atlas Labeling Beyond the Cranial Vault (BTCV), công bố kèm hội nghị MICCAI 2015 và phân phối qua nền tảng Synapse [10]. Bộ dữ liệu gồm 30 ca chụp cắt lớp vi tính vùng bụng có tiêm thuốc cản quang, mỗi ca là một khối ba chiều đã được chuyên gia khoanh vùng thủ công cho mười ba cơ quan. Dữ liệu được cung cấp miễn phí cho mục đích nghiên cứu sau khi người dùng đăng ký tài khoản và chấp nhận điều khoản sử dụng của ban tổ chức; khóa luận không thu thập thêm bất kỳ dữ liệu bệnh nhân nào và không xử lý thông tin định danh.

Theo thông lệ đã được TransUNet [8] và phần lớn các công trình đối chiếu trong khóa luận sử dụng, 30 ca được chia cố định thành 18 ca huấn luyện và 12 ca kiểm thử, thường được ký hiệu gọn là cách chia 18/12. Cách chia này được giữ nguyên không đổi cho cả năm cấu hình, và việc dùng đúng cách chia chuẩn là điều kiện để các con số của khóa luận có thể đặt cạnh những kết quả đã công bố ở mục 4.5. Trong số mười ba cơ quan có nhãn, khóa luận dùng thiết lập tám cơ quan quen thuộc gồm động mạch chủ, túi mật, thận trái, thận phải, gan, tuyến tụy, lách và dạ dày, cộng thêm lớp nền – tức bài toán phân loại chín lớp cho từng điểm ảnh.

Về tiền xử lý, giá trị Hounsfield được cắt ngưỡng về cửa sổ mô mềm rồi chuẩn hóa về khoảng từ 0 đến 1; mỗi lát cắt ngang được lấy mẫu lại về kích thước 224×224 và được nhân thành ba kênh giống nhau để dùng được trọng số ResNet-50 tiền huấn luyện trên ImageNet-21k. Khóa luận cố ý giữ tiền xử lý ở mức tối thiểu và giống hệt nhau giữa các cấu hình; các phép tăng cường tương phản như CLAHE đã được thử nhưng không được đưa vào vì làm giảm kết quả trên lớp tuyến tụy. Toàn bộ bước tiền xử lý giữ đúng như công trình TransUNet gốc [8] để kết quả có thể đối chiếu trực tiếp.

Một điểm cần nêu tường minh vì rất dễ gây nhầm lẫn khi đối chiếu số liệu giữa các công trình là bộ dữ liệu này có hai đơn vị đếm khác nhau. Con số 18 và 12 là số bệnh nhân, trong khi số mẫu huấn luyện thực tế là số lát cắt hai chiều trích ra từ 18 ca đó. Bảng 4.1 trình bày đầy đủ hai đơn vị đếm này cùng quy trình dữ liệu tương ứng ở hai giai đoạn.

Bảng 4.1. Quy trình dữ liệu và hai đơn vị đếm được nêu tường minh.

Khía cạnh	Huấn luyện (theo lát cắt)	Kiểm thử (theo khối)
Số bệnh nhân (ca CT)	18 trong tổng số 30 ca	12 trong tổng số 30 ca
Số mẫu thực tế sử dụng	2.211 lát cắt ngang hai chiều trích từ 18 ca (88–195 lát mỗi ca, trung bình 122,8)	12 khối ba chiều hoàn chỉnh; các lát cắt không được dùng như mẫu độc lập
Cách lưu trữ	Một tệp .npz cho mỗi lát cắt (ảnh, nhãn)	Một tệp .h5 cho mỗi ca (ảnh, nhãn)
Tệp chỉ mục	train.txt	test_vol.txt
Chuẩn bị đầu vào	Đổi kích thước về 224×224, chuyển sang tensor, lập kênh xám thành 3 kênh ([3, 224, 224])	Nạp một khối ba chiều; dự đoán lần lượt từng lát cắt ngang
Mức thao tác	Tối ưu trên từng lát cắt hai chiều	Ghép dự đoán các lát thành khối ba chiều; chỉ số được tính ở mức khối

Bảng 4.1 làm rõ một điểm dễ bị hiểu nhầm: huấn luyện thao tác trên 2.211 mẫu trong khi kiểm thử thao tác trên 12 khối, dù cả hai đều lấy từ cùng một bộ dữ liệu 30 ca.

4.2 Cấu hình hệ thống và môi trường thực nghiệm

Mọi lần chạy trong khóa luận đều được thực hiện trên cùng một cấu hình phần cứng và phần mềm, vì thay đổi môi trường giữa các lần chạy sẽ làm mất ý nghĩa của phép so sánh có kiểm soát. Phần huấn luyện và suy luận chạy trên một card đồ họa NVIDIA Tesla T4 dung lượng bộ nhớ 16 GB, kèm khoảng 13 GB bộ nhớ hệ thống. Phần mềm gồm Python 3, thư viện PyTorch với hỗ trợ CUDA, cùng các thư viện phụ trợ để đọc ảnh y khoa định dạng NIfTI, tính chỉ số phân đoạn và vẽ đồ thị.

Việc thực nghiệm bị ràng buộc bởi bộ nhớ của card đồ họa: kích thước lô 24 với ảnh đầu vào 224×224 là mức lớn nhất còn nạp vừa 16 GB đối với cấu hình nặng nhất trong năm cấu hình. Chính ràng buộc này quyết định ngân sách huấn luyện được trình bày ở mục sau, và cũng là lý do khóa luận chỉ huấn luyện mỗi cấu hình một lần với hạt giống ngẫu nhiên cố định thay vì lặp lại nhiều lần để tính khoảng tin cậy. Ngân sách huấn luyện được chọn bám sát ngân sách mà công trình TransUNet gốc dùng cho cùng bộ dữ liệu [8].

Về ngân sách huấn luyện, mỗi cấu hình được huấn luyện 150 vòng với kích thước lô 24 trên một card đồ họa Tesla T4. Với khoảng hơn hai nghìn lát cắt huấn luyện, ngân sách này tương đương xấp xỉ mười bốn nghìn bước cập nhật, gần với ngân sách mà công trình TransUNet gốc sử dụng cho cùng bộ dữ liệu. Việc chọn ngân sách tương đương giúp so sánh giữa cấu hình nền tái lập và các biến thể trở nên công bằng, đồng thời cho thấy cấu hình nền trong khóa luận là một mốc so sánh hợp lý chứ không phải một mô hình bị huấn luyện thiếu.

4.3 Giao thức huấn luyện và độ đo đánh giá

Toàn bộ năm cấu hình được huấn luyện và đánh giá dưới cùng một giao thức, tóm tắt trong Bảng 4.2. Nguyên tắc xuyên suốt là chỉ để một biến thay đổi: vị trí đặt mô-đun chú ý. Mọi yếu tố còn lại, từ cách chia dữ liệu, kích thước đầu vào, mạng nền, số vòng lặp huấn luyện, thuật toán tối ưu, hàm mất mát cho tới quy trình đánh giá, đều được giữ cố định.

Bảng 4.2. Thiết lập huấn luyện và đánh giá dùng chung cho các lần chạy.

Thành phần	Giá trị
Dataset	Synapse multi-organ CT
Train/test	18 ca huấn luyện, 12 khối kiểm thử
Input size	224×224
Số lớp	9, gồm nền và 8 cơ quan
Backbone	R50-ViT-B/16, tiền huấn luyện ImageNet-21k
Epoch	150

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Thành phần	Giá trị
Batch size	24
Optimizer	SGD (Stochastic Gradient Descent), momentum 0,9
Learning rate	0.01, suy giảm đa thức với số mũ 0.9
Loss	$0.5 \mathcal{L}_{CE} + 0.5 \mathcal{L}_{Dice}$
Seed	1234
Phần cứng	NVIDIA Tesla T4

Việc cố định giao thức là điều kiện tiên quyết để kết quả có thể diễn giải được. Nếu hai cấu hình được huấn luyện với số vòng lặp khác nhau hoặc tốc độ học khác nhau, chênh lệch quan sát được sẽ không còn quy về vị trí attention. Cũng vì lý do đó, khóa luận không cố gắng tinh chỉnh riêng siêu tham số cho từng cấu hình, dù việc đó có thể làm đẹp con số của cấu hình đề xuất.

Quy trình đánh giá cần được mô tả rõ vì nó ảnh hưởng trực tiếp đến ý nghĩa của các con số. Trong lúc huấn luyện, mô hình làm việc trên từng lát cắt hai chiều; nhưng khi đánh giá, với mỗi ca kiểm thử, mô hình dự đoán tuần tự tất cả các lát rồi ghép lại thành một khối ba chiều hoàn chỉnh trước khi tính chỉ số. Các chỉ số trùng khớp được tính trên toàn khối, còn HD95 được tính trong không gian ba chiều có tính đến khoảng cách vật lý thực giữa các điểm ảnh, kể cả khoảng cách lớn hơn giữa hai lát cắt liền kề. Cách tính ở mức khối là bắt buộc, bởi đại lượng có ý nghĩa lâm sàng là toàn bộ cơ quan chứ không phải một lát riêng lẻ.

Về độ đo, khóa luận sử dụng đúng bốn chỉ số Dice, Jaccard, HD95 và recall đã được định nghĩa và giải thích đầy đủ ở mục 2.10 và mục 2.11, nên ở đây không trình bày lại công thức. Chỉ nhắc lại hai quy ước đọc kết quả có ảnh hưởng trực tiếp tới các bảng số phía sau. Thứ nhất, Dice, Jaccard và recall càng cao càng tốt còn HD95 càng thấp càng tốt, nên một cấu hình chỉ được xem là tốt hơn toàn diện khi dẫn đầu đồng thời ở nhóm chỉ số trùng khớp vùng và nhóm chỉ số sai lệch biên. Thứ hai, mọi chỉ số đều được tính ở mức khối ba chiều sau khi ghép dự đoán của từng lát cắt, và với những ca mà nhãn tham chiếu không chứa tuyến tụy nhưng mô hình vẫn dự đoán có thì Dice và Jaccard của ca đó được quy ước bằng 0. Cả bốn chỉ số

đều được tính theo định nghĩa chuẩn cho phân đoạn ba chiều [16], trên cùng cách chia dữ liệu mà TransUNet [8] sử dụng.

4.4 Kết quả và phân tích

Bảng 4.3 trình bày kết quả trên lớp tuyến tụy của năm cấu hình, đo ở mức khối ba chiều trên 12 ca kiểm thử, kèm số tham số của từng cấu hình để đối chiếu chi phí với lợi ích.

Bảng 4.3. Kết quả phân đoạn tuyến tụy của TransUNet nền và bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối), kèm số tham số của từng cấu hình.

Cấu hình	Tham số (triệu)	Dice ↑	HD95 ↓	Jaccard ↑	Recall ↑
TransUNet nền	105,28	54,37%	15,38	39,66%	44,41%
Nhánh 1 – CBAM đa tỷ lệ	106,18	58,93%	13,20	44,24%	50,22%
Nhánh 2 – CBAM trước bước tạo token (đề xuất)	106,46	59,23%	12,97	43,94%	48,94%
Nhánh 3 – CBAM + RA trên nhánh nối tắt	106,74	58,32%	32,17	42,95%	52,33%
Nhánh 4 – CBAM + RA sau phép nối	107,59	55,95%	13,13	40,99%	46,28%


Bảng 4.4 trình bày mức chênh lệch của bốn nhánh đề xuất so với TransUNet nền. Các giá trị được tính trực tiếp từ những con số trong Bảng 4.3.

Bảng 4.4. Mức thay đổi của bốn nhánh đề xuất (CBAM đa tỷ lệ, CBAM trước bước tạo token, CBAM + RA trên nhánh nối tắt, CBAM + RA sau phép nối) so với TransUNet nền.

Cấu hình	Δ Dice	Δ HD95	Δ Jaccard	Δ Recall
Nhánh 1 – CBAM đa tỷ lệ	+4,56	-2,18	+4,58	+5,81
Nhánh 2 –	+4,86	-2,41	+4,28	+4,53

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Cấu hình	Δ Dice	Δ HD95	Δ Jaccard	Δ Recall
CBAM trước bước tạo token (đề xuất)				
Nhánh 3 – CBAM + RA trên nhánh nối tắt	+3,95	+16,79	+3,29	+7,92
Nhánh 4 – CBAM + RA sau phép nối	+1,58	-2,25	+1,33	+1,87



Hình 4.1. Bốn chỉ số tuyến tụy của năm cấu hình thực nghiệm. Cấu hình đặt CBAM trước bước tạo token là cấu hình duy nhất dẫn đầu đồng thời ở Dice và HD95.

Bốn nhận xét sau đây được rút ra trực tiếp từ ba bảng và hình vừa trình bày; mỗi nhận xét gắn với một câu hỏi thiết kế cụ thể.

Nhận xét thứ nhất liên quan tới câu hỏi nghiên cứu chính. Cấu hình đặt CBAM trước bước tạo token đạt Dice cao nhất là 59,23 phần trăm và HD95 thấp nhất là 12,97 milimét. So với cấu hình nền, mức cải thiện là 4,86 điểm Dice và 2,41 milimét HD95. Điều đáng chú ý không nằm ở độ lớn của từng con số mà ở chỗ đây là cấu hình duy nhất dẫn đầu đồng thời cả hai nhóm chỉ số. Nói cách khác, việc tinh

chính đặc trưng ẩn trước bước tạo token cải thiện cùng lúc độ trùng khớp vùng và chất lượng biên, thay vì đánh đổi cái này lấy cái kia.

Điều quan trọng là chênh lệch này không đến từ dung lượng mô hình. Như đã nêu ở mục 3.3, cả bốn cấu hình có attention đều nằm trong khoảng 106,18 đến 107,59 triệu tham số, so với 105,28 triệu của cấu hình nền; riêng cấu hình đề xuất chỉ thêm khoảng 1,1 phần trăm tham số nhưng lại cho kết quả tốt nhất ở cả Dice lẫn HD95. Nói cách khác, cái tạo ra khác biệt là vị trí can thiệp chứ không phải số tham số được thêm vào.

Nhận xét thứ hai liên quan tới cấu hình đa tỷ lệ. Cấu hình này cũng cải thiện rõ so với nền, với Dice 58,93 phần trăm, chỉ thấp hơn cấu hình chính 0,30 điểm; thậm chí nó còn đạt Jaccard cao nhất là 44,24 phần trăm. Như vậy, cả hai phương án can thiệp ở phía bộ mã hóa đều có giá trị. Tuy nhiên, điều đáng suy ngẫm là cấu hình đa tỷ lệ can thiệp vào ba tầng đặc trưng và thêm cả nhánh chiếu lẫn hệ số hợp nhất học được, tức là phức tạp hơn hẳn, nhưng vẫn không vượt được cấu hình chỉ tinh chỉnh một tầng duy nhất về Dice và HD95. Kết quả này bác bỏ giả định rằng can thiệp càng rộng thì càng tốt, và củng cố luận điểm trung tâm của khóa luận: vị trí quan trọng hơn quy mô.

Nhận xét thứ ba liên quan tới chú ý ngược trên nhánh nội tắt. Cấu hình này đạt recall cao nhất trong toàn bộ thực nghiệm, 52,33 phần trăm, cao hơn cấu hình nền tới 7,92 điểm. Nếu chỉ nhìn recall, đây sẽ là cấu hình tốt nhất. Nhưng HD95 của nó là 32,17 milimét, tức là tệ hơn cấu hình nền tới 16,79 milimét và cao gấp gần hai lần rưỡi so với cấu hình chính. Hiện tượng này khớp chính xác với dự đoán lý thuyết ở mục 2.9: chú ý ngược đẩy mô hình mở rộng dự đoán sang vùng chưa chắc chắn, nhờ đó bắt được nhiều phần cơ quan hơn nhưng đồng thời sinh ra những vùng dương giả nằm xa, làm sai lệch biên tăng vọt. Đây là minh chứng thuyết phục cho lập luận rằng không thể chọn mô hình bằng một chỉ số đơn lẻ.

Nhận xét thứ tư liên quan tới chú ý ngược sau phép nối. Cấu hình này cải thiện so với nền nhưng ở mức khiêm tốn nhất trong bốn cấu hình, và không vượt được cấu hình chính ở bất kỳ chỉ số nào. Điều đó cho thấy khi biểu diễn Transformer đã

hình thành và đã được hợp nhất với đặc trưng nổi bật, dư địa để một mô-đun chú ý tạo khác biệt đã hẹp lại đáng kể.

Tổng hợp bốn nhận xét, có thể trả lời ba câu hỏi nghiên cứu đặt ra ở mục 1.2. Với câu hỏi thứ nhất, câu trả lời là có: tinh chỉnh đặc trưng ẩn bằng CBAM trước bước tạo token cải thiện rõ rệt kết quả tuyển tụy so với cấu hình nền. Với câu hỏi thứ hai, câu trả lời cũng là có, nhưng cần diễn đạt thận trọng: cấu hình chính vượt các phương án còn lại trên hai chỉ số quan trọng nhất, dù cấu hình đa tỷ lệ vẫn cạnh tranh về Jaccard. Với câu hỏi thứ ba, cấu hình chính là cấu hình có hành vi cân bằng nhất, và điều đó cho thấy việc chọn mô hình nên dựa trên hành vi kết hợp giữa trùng khớp vùng và sai lệch biên.

Ngoài lớp tuyển tụy, kết quả trên các cơ quan còn lại cho một bức tranh không đồng nhất: một số cơ quan như thận, lách và dạ dày được cải thiện, trong khi động mạch chủ và gan giảm nhẹ. Điều này dẫn tới một kết luận có giới hạn rõ ràng: can thiệp trước bước tạo token có lợi cho tuyển tụy trong giao thức đã báo cáo, nhưng chưa đủ cơ sở để khẳng định một ưu thế đồng đều trên toàn bộ các cơ quan.

Bảng 4.5. Kết quả theo từng cơ quan của cấu hình nền và cấu hình đề xuất. Giá trị Δ H95 mang dấu âm là có lợi.


Cơ quan	Dice nền	Dice CBAM	Δ Dice	H95 nền	H95 CBAM	Δ H95
Động mạch chủ	87,45	86,59	-0,85	5,37	13,42	+8,05
Túi mật	50,32	50,84	+0,53	40,34	32,02	-8,32
Thận trái	81,32	85,62	+4,30	49,97	34,62	-15,36
Thận phải	78,23	81,94	+3,71	49,34	31,54	-17,80
Gan	94,34	93,79	-0,55	25,89	33,34	+7,45
Tuyển tụy	54,37	59,23	+4,86	15,38	12,97	-2,41
Lách	85,69	89,86	+4,17	53,12	29,16	-23,96
Dạ dày	74,54	77,31	+2,77	18,46	17,62	-0,83

Bảng 4.5 khẳng định lại kết luận có giới hạn đã nêu. Dice tăng ở túi mật, hai quả thận, tuyển tụy, lách và dạ dày, nhưng giảm nhẹ ở động mạch chủ và gan. Về sai lệch biên, mức cải thiện rõ nhất thuộc về lách với 23,96 milimét và hai quả thận

với 15,36 và 17,80 milimét, trong khi động mạch chủ và gan xấu đi lần lượt 8,05 và 7,45 milimét. Vì vậy khóa luận chỉ kết luận trong phạm vi lớp tuyến tụy chứ không khẳng định một lợi thế đồng đều trên toàn bộ tám cơ quan.

Kết quả này ăn khớp với lập luận lý thuyết đã trình bày ở Chương 2. Việc tinh chỉnh đặc trưng ẩn trước bước tạo token giúp những kênh và những vùng liên quan tới tuyến tụy được nhấn mạnh, nhờ đó chuỗi token đưa vào Transformer mang tính phân biệt cao hơn. Vì tuyến tụy là cơ quan nhỏ, ranh giới mờ và dễ nhầm với cấu trúc lân cận, đây đúng là loại cơ quan hưởng lợi nhiều nhất từ một biểu diễn đầu vào sạch hơn. Ngược lại, với những cơ quan vốn đã dễ như gan, dư địa cải thiện gần như không còn, và một thay đổi nhỏ trong phân bố đặc trưng thậm chí có thể làm chỉ số dao động nhẹ theo chiều bất lợi. Bức tranh không đồng nhất giữa các cơ quan vì thế không mâu thuẫn với giả thuyết, mà phản ánh đúng việc lợi ích tập trung ở nơi bài toán khó.

Nhìn từ góc độ chọn mô hình, hình so sánh trực quan giữa Dice và HD95 cho thấy một sự đánh đổi rõ ràng giữa các cấu hình. Cấu hình chú ý ngược trên nhánh nói tắt nằm lệch hẳn về phía độ phủ cao nhưng sai lệch biên lớn, trong khi cấu hình đề xuất nằm ở vùng cân bằng, dẫn đầu cả hai trục. Chính hình ảnh này là lý do khóa luận không chọn mô hình theo một chỉ số đơn lẻ: nếu chỉ nhìn recall, ta sẽ chọn nhầm một cấu hình có đường viền kém xa; nếu chỉ nhìn Dice, ta bỏ qua thông tin về chất lượng biên. Việc đọc đồng thời hai trục là cách duy nhất để nhận ra cấu hình nào thực sự tốt một cách toàn diện.



Hình 4.2. Minh họa kết quả phân đoạn định tính từ các cấu hình thực nghiệm.

Hình minh họa định tính cho thấy cấu hình đề xuất khôi phục được nhiều phần đường viền tuyến tụy hơn so với cấu hình nền trên các lát cắt được chọn, phù hợp với xu hướng mà các chỉ số định lượng phản ánh.

4.5 So sánh với các công trình đã công bố

Bảng 4.3 và Bảng 4.4 so sánh năm cấu hình trong cùng một giao thức do khóa luận tự chạy. Để đặt kết quả vào bối cảnh rộng hơn, mục này đối chiếu cấu hình đề xuất với các con số đã công bố trên cùng bộ dữ liệu Synapse với cách chia 18/12 quen thuộc.

Bảng 4.6. So sánh với các kết quả đã công bố trên bộ dữ liệu Synapse (cách chia chuẩn 18/12).

Phương pháp	Kiểu kiến trúc	Dice tuyến tụy ↑	Dice trung bình ↑	HD95 trung bình ↓
V-Net [15]	CNN ba chiều	40,05	68,81	—
TransUNet [8], [27]	Lai CNN – Transformer	55,86	77,48	31,69
Swin-Unet [22]	Transformer thuần	56,58	79,13	21,55

Phương pháp	Kiểu kiến trúc	Dice tuyến tụy ↑	Dice trung bình ↑	HD95 trung bình ↓
Att-UNet [19]	CNN kèm công chú ý	58,04	77,77	36,02
CBAM- TransUNet (khóa luận)	Lai kèm CBAM trước tạo token	59,23	78,15	25,59

Cần nói rõ giới hạn của phép so sánh này. Các dòng của những phương pháp trước được lấy nguyên từ công bố gốc chứ không được chạy lại trong khuôn khổ khóa luận; chỉ dòng cuối cùng là kết quả do khóa luận tự đo. Vì mỗi công trình có thể khác nhau về tiền xử lý, cách kiểm định chéo, hậu xử lý hay việc huấn luyện theo khối ba chiều, bảng này chỉ cho biết vị trí tương đối của phương pháp trong tài liệu chứ không phải một so sánh đối đầu có kiểm soát. Phép so sánh có kiểm soát vẫn là Bảng 4.3.

Trong phạm vi đó, có thể rút ra ba nhận xét. Thứ nhất, ở riêng lớp tuyến tụy, cấu hình đề xuất đạt Dice 59,23 phần trăm, cao hơn tất cả các phương pháp được đối chiếu, trong đó có Att-UNet [19] với 58,04 phần trăm và Swin-Unet [22] với 56,58 phần trăm. Thứ hai, tính trung bình trên tám cơ quan, cấu hình đề xuất đạt Dice trung bình 78,15 phần trăm và HD95 trung bình 25,59 milimét, tốt hơn cả TransUNet [8], [27] với 77,48 phần trăm và 31,69 milimét, lẫn Att-UNet [19] với 77,77 phần trăm và 36,02 milimét. Thứ ba, Swin-Unet [22] vẫn dẫn đầu về trung bình đa cơ quan với 79,13 phần trăm và HD95 21,55 milimét, và những thiết kế gần đây khai thác biểu diễn miền tần số còn báo cáo trung bình đa cơ quan cao hơn nữa [26]. Nói cách khác, đóng góp của khóa luận nằm ở lớp tuyến tụy chứ không phải ở một khẳng định vượt trội toàn diện.

4.6 Khả năng tái lập và nguồn truy vết

Mỗi lần chạy đều xuất ra một tập artifact đầy đủ, được lưu lại làm nguồn truy vết cho các con số được báo cáo. Cách tổ chức này bảo đảm rằng mọi giá trị trong Bảng 4.3 đều có thể lần ngược về tệp kết quả gốc thay vì được chép lại thủ công.

Bảng 4.7. Thành phần artifact phục vụ khả năng tái lập thực nghiệm.

Artifact	Ý nghĩa
manifest.json	Tóm tắt lần chạy, danh sách tệp xuất và siêu dữ liệu
config.json	Lưu tham số kiến trúc và tham số đánh giá
commands.json	Lưu lệnh huấn luyện và kiểm thử đã sử dụng
metrics.json	Lưu Dice, HD95, Jaccard và recall tổng hợp
per_case_metrics.csv	Chỉ số theo từng ca và từng lớp
per_class_metrics.csv	Chỉ số trung bình theo từng lớp
confusion_matrix.json	Nguồn tính recall theo lớp
predictions/*.nii.gz	Khối dự đoán, nhãn tham chiếu và ảnh gốc

4.7 Hạn chế của thực nghiệm

Khóa luận có một số hạn chế cần nêu rõ để tránh diễn giải quá mức kết quả.

Hạn chế thứ nhất thuộc về phạm vi dữ liệu. Toàn bộ kết luận được rút ra trên một bộ dữ liệu công khai duy nhất với một giao thức cố định. Do đó, các phát biểu chỉ có hiệu lực trong phạm vi giao thức đã báo cáo, và không thể suy rộng thành khẳng định về hiệu năng tuyệt đối so với các công trình dùng tiền xử lý, hậu xử lý hay cách huấn luyện khác.

Hạn chế thứ hai thuộc về mức độ tách bạch thành phần. Cấu hình đề xuất là một khối gồm chú ý theo kênh, chú ý theo không gian và kết nối phần dư. Khóa luận đo hiệu quả của cả khối đặt tại một vị trí, chứ chưa thực hiện các thí nghiệm loại bỏ từng thành phần với số tham số được cân bằng. Vì vậy, chưa thể khẳng định phần đóng góp riêng của từng nhánh bên trong khối.

Hạn chế thứ ba thuộc về cách mô hình xử lý dữ liệu ba chiều. Việc huấn luyện theo từng lát cắt hai chiều khiến mô hình không khai thác được quan hệ giữa các lát

liên tiếp, trong khi thông tin đó có thể hữu ích với một cơ quan kéo dài như tuyển tụy.

Hạn chế thứ tư thuộc về phạm vi kết luận. Kết quả trên các cơ quan ngoài tuyển tụy không đồng nhất, nên khóa luận chỉ kết luận trong phạm vi lớp tuyển tụy. Đồng thời, mọi kết quả trong khóa luận là kết quả nghiên cứu kỹ thuật trên dữ liệu công khai, không phải bằng chứng cho bất kỳ khẳng định lâm sàng nào.

4.8 Tổng kết chương

Chương 4 đã trả lời bằng số liệu cho câu hỏi vị trí đặt ra từ Chương 1. Năm cấu hình được huấn luyện và đánh giá dưới một giao thức hoàn toàn giống nhau trên bộ Synapse với cách chia chuẩn 18/12, chỉ khác nhau ở vị trí đặt mô-đun chú ý. Nhánh đặt CBAM trước bước tạo token đạt Dice tuyển tụy 59,23 phần trăm và HD95 12,97 milimét, cải thiện so với cấu hình nền lần lượt 4,86 điểm và 2,41 milimét, đồng thời là cấu hình duy nhất dẫn đầu ở cả hai nhóm chỉ số.

Ba nhánh đối chứng cho thấy kết luận không tầm thường. Nhánh đa tỷ lệ cũng cải thiện rõ nhưng không vượt được nhánh chỉ can thiệp một tầng, nghĩa là can thiệp nhiều tầng hơn không đồng nghĩa với tốt hơn. Nhánh chú ý ngược trên nhánh nổi tắt đạt recall cao nhất là 52,33 phần trăm nhưng HD95 vọt lên 32,17 milimét, minh họa rõ vì sao không thể chọn mô hình theo một chỉ số duy nhất. Nhánh chú ý ngược sau phép nổi cải thiện khiêm tốn nhất, cho thấy dư địa can thiệp thu hẹp dần khi càng đi sâu về phía bộ giải mã. Bảng 3.5 và cột tham số của Bảng 4.3 loại trừ khả năng chênh lệch đến từ dung lượng mô hình.

Chương cũng nêu rõ ranh giới của kết luận. Kết quả theo từng cơ quan không đồng nhất: sáu cơ quan cải thiện nhưng động mạch chủ và gan giảm nhẹ, nên phát biểu của khóa luận chỉ có hiệu lực trong phạm vi lớp tuyển tụy và trong đúng giao thức đã báo cáo. Phép đối chiếu với các công trình đã công bố chỉ mang tính tham chiếu vì các dòng khác được lấy nguyên từ công bố gốc. Bốn hạn chế đã được liệt kê tường minh, và chính chúng là cơ sở cho phần đánh giá ưu nhược điểm cùng các hướng phát triển ở Chương 5.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Khóa luận đã nghiên cứu ảnh hưởng của vị trí đặt mô-đun chú ý trong kiến trúc TransUNet đối với bài toán phân đoạn tuyến tụy trên ảnh CT bụng. Xuất phát từ nhận xét rằng đặc trưng ẩn ngay trước bước tạo token là biểu diễn cuối cùng còn hội đủ hai tính chất – đủ trừu tượng về ngữ nghĩa và vẫn còn cấu trúc lưới hai chiều – khóa luận đề xuất chèn một khối CBAM dạng phần dư tại đúng vị trí đó, giữ nguyên toàn bộ phần còn lại của kiến trúc.

Về mặt lý thuyết, khóa luận đã hệ thống hóa các nền tảng liên quan theo một mạch liên lạc, từ đặc điểm dữ liệu CT và bản chất bài toán phân đoạn, qua mạng tích chập và học phần dư, kiến trúc U-Net, các cơ chế chú ý, Transformer và Vision Transformer, cho tới kiến trúc lai TransUNet, chú ý ngược, hàm mất mát và hệ chỉ số đánh giá. Mạch trình bày này cho thấy một quy luật xuyên suốt: phần lớn tiến bộ trong lĩnh vực đến từ việc bố trí lại luồng thông tin chứ không chỉ từ việc phát minh khối tính toán mới. Chính quy luật đó dẫn tới khoảng trống mà khóa luận khai thác.

Về mặt thực nghiệm, năm cấu hình được so sánh dưới một giao thức cố định. Cấu hình đề xuất đạt Dice tuyến tụy cao nhất là 59,23 phần trăm và HD95 thấp nhất là 12,97 milimét, cải thiện so với cấu hình nền lần lượt 4,86 điểm Dice và 2,41 milimét. Quan trọng hơn con số, đây là cấu hình duy nhất dẫn đầu đồng thời ở cả hai nhóm chỉ số. Hai kết quả đối chứng bổ sung cho bức tranh này: cấu hình đa tỷ lệ tuy phức tạp hơn nhiều nhưng không vượt được cấu hình chính, cho thấy vị trí quan trọng hơn quy mô can thiệp; còn cấu hình chú ý ngược trên nhánh nổi tắt tuy đạt recall cao nhất nhưng lại có HD95 tệ nhất, cho thấy một chỉ số đơn lẻ có thể dẫn tới kết luận sai lệch.

Kết luận tổng quát của khóa luận là: trong kiến trúc lai giữa mạng tích chập và Transformer, điểm nổi ngay trước bước tạo token là một vị trí can thiệp có giá trị và xứng đáng được xem xét như một biến thiết kế độc lập. Kết luận này được phát biểu trong phạm vi giao thức đã báo cáo và trong phạm vi lớp tuyến tụy.

5.2 Ưu điểm và nhược điểm của phương pháp đề xuất

Trước khi bàn tới các hướng tiếp nối, cần đánh giá thẳng thắn phương pháp đã đề xuất trên cả hai mặt.

Ưu điểm thứ nhất là chi phí rất thấp so với lợi ích thu được. Khối CBAM phần dư chỉ thêm 1,18 triệu tham số, tương đương khoảng 1,1 phần trăm so với 105,28 triệu tham số của cấu hình nền, nhưng mang lại 4,86 điểm Dice và giảm 2,41 milimét HD95 trên lớp tuyến tụy. Ưu điểm thứ hai là tính không xâm lấn về mặt kiến trúc: vì khối bảo toàn hình dạng tensor $1024 \times 14 \times 14$, số token, số chiều token, số khối Transformer, bộ giải mã và toàn bộ đường nối tất đều giữ nguyên, nên phương pháp có thể ghép vào một hệ thống TransUNet sẵn có mà không phải chỉnh lại siêu tham số. Ưu điểm thứ ba nằm ở kết nối phần dư: nếu cơ chế chú ý không có ích, mạng chỉ cần đẩy phần hiệu chỉnh về gần 0 là khối trở thành ánh xạ đồng nhất [11], nên trong trường hợp xấu nhất mô hình cũng không tệ hơn cấu hình nền. Ưu điểm thứ tư là phương pháp cải thiện đồng thời cả độ trùng khớp vùng lẫn sai lệch biên, khác với ba nhánh đối chứng vốn chỉ mạnh ở một khía cạnh.

Nhược điểm thứ nhất là khóa luận chưa tách bạch được đóng góp của từng thành phần bên trong khối. Cấu hình đề xuất là một gói gồm chú ý theo kênh, chú ý theo không gian và kết nối phần dư; khóa luận đo hiệu quả của cả gói đặt tại một vị trí chứ chưa thực hiện các thí nghiệm loại bỏ từng thành phần với số tham số được cân bằng, nên chưa thể khẳng định thành phần nào đóng vai trò quyết định. Nhược điểm thứ hai là lợi ích không đồng đều giữa các cơ quan: sáu trong tám cơ quan được cải thiện nhưng động mạch chủ và gan giảm nhẹ cả về Dice lẫn HD95, cho thấy việc làm nổi bật đặc trưng có lợi cho tuyến tụy có thể làm mờ tín hiệu của những cơ quan lớn vốn đã dễ phân đoạn. Nhược điểm thứ ba là phương pháp vẫn làm việc theo từng lát cắt hai chiều nên không khai thác được tính liên tục giữa các lát, trong khi tuyến tụy là cơ quan kéo dài dọc theo trục cơ thể. Nhược điểm thứ tư thuộc về phạm vi kiểm chứng: mọi kết luận mới chỉ dựa trên một bộ dữ liệu công khai duy nhất, một cách chia cố định và một lần chạy cho mỗi cấu hình với hạt giống ngẫu nhiên được cố định, nên chưa có khoảng tin cậy thống kê đi kèm.

Nhìn tổng thể, các ưu điểm cho thấy vị trí ngay trước bước tạo token là một biến thiết kế đáng được xem xét độc lập, còn các nhược điểm khoanh vùng rõ những gì cần làm tiếp. Mục sau trình bày các hướng đó.

5.3 Hướng phát triển

Từ những hạn chế đã nêu, có thể xác định một số hướng tiếp nối.

Hướng thứ nhất là tách bạch đóng góp của từng thành phần bên trong khối được đề xuất, bằng các thí nghiệm loại bỏ có cân bằng số tham số. Việc này sẽ trả lời câu hỏi liệu lợi ích đến từ chú ý theo kênh, chú ý theo không gian, kết nối phần dư, hay từ sự kết hợp của chúng.

Hướng thứ hai là mở rộng đánh giá sang các bộ dữ liệu tuyến tụy khác. Nếu kết luận về vị trí can thiệp vẫn giữ nguyên trên dữ liệu có đặc điểm thu nhận khác, độ tin cậy của kết luận sẽ tăng lên đáng kể.

Hướng thứ ba là khai thác thông tin ba chiều, chẳng hạn bằng cách đưa vào một số lát cắt lân cận thay vì một lát đơn lẻ. Cách làm này có thể giúp mô hình tận dụng tính liên tục của tuyến tụy dọc theo trục cơ thể mà không phải chuyển hoàn toàn sang mô hình ba chiều vốn tốn kém.

Hướng thứ tư là mở rộng khảo sát vị trí sang chú ý ngược đa tỷ lệ ở phía bộ giải mã, nhằm kiểm tra xem hiện tượng recall tăng nhưng biên xấu đi có được khắc phục khi cơ chế này được áp dụng ở nhiều mức độ phân giải hay không.

Hướng thứ năm là phân tích lỗi theo hướng giải phẫu: xác định những vùng nào của tuyến tụy thường bị bỏ sót và những cấu trúc nào thường bị nhầm lẫn. Một phân tích như vậy sẽ có giá trị hơn nhiều so với việc chỉ theo đuổi một con số cao hơn, và là bước cần thiết trước khi nghĩ tới bất kỳ ứng dụng thực tế nào.

TÀI LIỆU THAM KHẢO

- [1] G. N. Hounsfield, “Computerized transverse axial scanning (tomography): Part 1. Description of system,” *Br. J. Radiol.*, vol. 46, no. 552, pp. 1016-1022, 1973, doi: 10.1259/0007-1285-46-552-1016.
- [2] G. Litjens et al., “A survey on deep learning in medical image analysis,” *Med. Image Anal.*, vol. 42, pp. 60-88, 2017, doi: 10.1016/j.media.2017.07.005.
- [3] H. R. Roth, L. Lu, A. Farag, H.-C. Shin, J. Liu, E. B. Turkbey, and R. M. Summers, “DeepOrgan: Multi-level Deep Convolutional Networks for Automated Pancreas Segmentation,” in *MICCAI*, 2015, pp. 556-564, doi: 10.1007/978-3-319-24553-9_68.
- [4] J. Ma et al., “AbdomenCT-1K: Is Abdominal Organ Segmentation a Solved Problem?,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 10, pp. 6695-6714, 2022, doi: 10.1109/TPAMI.2021.3100536.
- [5] H. Sung, J. Ferlay, R. L. Siegel, M. Laversanne, I. Soerjomataram, A. Jemal, and F. Bray, “Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries,” *CA Cancer J. Clin.*, vol. 71, no. 3, pp. 209-249, 2021, doi: 10.3322/caac.21660.
- [6] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, LNCS 9351, 2015, pp. 234-241, doi: 10.1007/978-3-319-24574-4_28.
- [7] A. Vaswani et al., “Attention Is All You Need,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017, doi: 10.48550/arXiv.1706.03762.
- [8] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, and Y. Zhou, “TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation,” *arXiv:2102.04306*, 2021, doi: 10.48550/arXiv.2102.04306.

- [9] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional Block Attention Module,” in Proc. Eur. Conf. Comput. Vis. (ECCV), 2018, pp. 3-19, doi: 10.1007/978-3-030-01234-2_1.
- [10] B. Landman et al., “MICCAI Multi-Atlas Labeling Beyond the Cranial Vault – Workshop and Challenge,” Synapse, 2015. [Online]. Available: <https://www.synapse.org/Synapse:syn3193805>. [Accessed: 05-08-2026].
- [11] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2016, pp. 770-778, doi: 10.1109/CVPR.2016.90.
- [12] A. Dosovitskiy et al., “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale,” in Proc. Int. Conf. Learn. Represent. (ICLR), 2021, doi: 10.48550/arXiv.2010.11929.
- [13] M. Antonelli et al., “The Medical Segmentation Decathlon,” Nat. Commun., vol. 13, art. no. 4128, 2022, doi: 10.1038/s41467-022-30695-9.
- [14] J. Long, E. Shelhamer, and T. Darrell, “Fully Convolutional Networks for Semantic Segmentation,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2015, pp. 3431-3440, doi: 10.1109/CVPR.2015.7298965.
- [15] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation,” in Proc. Fourth Int. Conf. 3D Vision (3DV), 2016, pp. 565-571, doi: 10.1109/3DV.2016.79.
- [16] A. A. Taha and A. Hanbury, “Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool,” BMC Medical Imaging, vol. 15, art. 29, 2015, doi: 10.1186/s12880-015-0068-x.
- [17] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, “UNet++: A Nested U-Net Architecture for Medical Image Segmentation,” in Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA), 2018, pp. 3-11, doi: 10.1007/978-3-030-00889-5_1.

- [18] F. Isensee et al., “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, vol. 18, pp. 203-211, 2021, doi: 10.1038/s41592-020-01008-z.
- [19] O. Oktay et al., “Attention U-Net: Learning Where to Look for the Pancreas,” *arXiv:1804.03999*, 2018, doi: 10.48550/arXiv.1804.03999.
- [20] J. M. J. Valanarasu, P. Oza, I. Hacihaliloglu, and V. M. Patel, “Medical Transformer: Gated Axial-Attention for Medical Image Segmentation,” in *MICCAI*, 2021, pp. 36-46, doi: 10.1007/978-3-030-87193-2_4.
- [21] A. Hatamizadeh et al., “UNETR: Transformers for 3D Medical Image Segmentation,” in *Proc. IEEE/CVF Winter Conf. Appl. Comput. Vis. (WACV)*, 2022, pp. 574-584, doi: 10.1109/WACV51458.2022.00181.
- [22] H. Cao et al., “Swin-Unet: Unet-Like Pure Transformer for Medical Image Segmentation,” in *Computer Vision – ECCV 2022 Workshops, LNCS 13803*, 2023, pp. 205-218, doi: 10.1007/978-3-031-25066-8_9.
- [23] H. Wang, P. Cao, J. Wang, and O. R. Zaiane, “UCTransNet: Rethinking the Skip Connections in U-Net from a Channel-Wise Perspective with Transformer,” in *Proc. AAAI Conf. Artif. Intell.*, vol. 36, no. 3, 2022, pp. 2441-2449, doi: 10.1609/aaai.v36i3.20144.
- [24] S. Zheng et al., “Rethinking Semantic Segmentation from a Sequence-to-Sequence Perspective with Transformers,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 6881-6890, doi: 10.1109/CVPR46437.2021.00681.
- [25] J. Hu, L. Shen, and G. Sun, “Squeeze-and-Excitation Networks,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 7132-7141, doi: 10.1109/CVPR.2018.00745.
- [26] F. Lu, J. Xu, Q. Sun, and Q. Lou, “FMD-TransUNet: abdominal multi-organ segmentation based on frequency domain multi-axis representation learning

- and dual attention mechanisms,” *Applied Intelligence*, vol. 56, no. 6, art. no. 211, 2026, doi: 10.1007/s10489-026-07240-y.
- [27] J. Chen et al., “TransUNet: Rethinking the U-Net Architecture Design for Medical Image Segmentation Through the Lens of Transformers,” *Medical Image Analysis*, vol. 97, art. 103280, 2024, doi: 10.1016/j.media.2024.103280.
- [28] S. Chen, X. Tan, B. Wang, and X. Hu, “Reverse Attention for Salient Object Detection,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2018, pp. 234-250, doi: 10.1007/978-3-030-01240-3_15.
- [29] D.-P. Fan et al., “PraNet: Parallel Reverse Attention Network for Polyp Segmentation,” in *MICCAI*, 2020, pp. 263-273, doi: 10.1007/978-3-030-59725-2_26.

PHỤ LỤC

Phụ lục A. Tóm tắt tham số và nguồn truy vết

Bảng P.1 liệt kê định danh của từng lần chạy, notebook tương ứng và thiết lập chính. Bảng này cho phép đối chiếu mỗi dòng kết quả trong Chương 4 với đúng lần chạy đã sinh ra nó.

Bảng P.1. Tóm tắt tham số dòng lệnh và nguồn truy vết cho các cấu hình.

Run ID	Notebook	Snapshot / thiết lập chính
baseline_reproduction	notebooks/01-baseline-transunet	vit=R50-ViT-B_16; epoch=150; batch=24; lr=0.01
mscaf_cnn_fusion_3scale	notebooks/02-mscaf-cbam-da-ty-le	vit=R50-ViT-B_16; epoch=150; batch=24; lr=0.01
pre_hidden_1_16_r16_run_03	notebooks/07-cbam-truoc-patch-embedding	vit=R50-ViT-B_16; epoch=150; batch=24; lr=0.01
reverse_attention_s0_r4_run_01	notebooks/05-cbam-reverse-attention-skip	vit=R50-ViT-B_16; epoch=150; batch=24; lr=0.01
reverse_bottleneck_fusion_s0_r4	notebooks/06-cbam-reverse-attention-fusion	vit=R50-ViT-B_16; epoch=150; batch=24; lr=0.01

Phụ lục B. Ghi chú đọc kết quả

Khi đối chiếu các con số trong khóa luận với tệp kết quả gốc, cần lưu ý ba quy ước sau.

Thứ nhất, mọi chỉ số được báo cáo là chỉ số của lớp tuyến tụy, tính ở mức khối ba chiều sau khi ghép dự đoán của các lát cắt thuộc cùng một ca. Các giá trị này không phải trung bình trên toàn bộ chín lớp.

Thứ hai, giá trị chênh lệch trong Bảng 4.4 được tính trực tiếp từ các giá trị đã làm tròn trong Bảng 4.3, nên có thể sai khác ở chữ số thập phân thứ hai so với chênh lệch tính từ giá trị chưa làm tròn trong tệp kết quả.

Thứ ba, với những ca mà nhãn tham chiếu không chứa tuyến tụy nhưng mô hình vẫn dự đoán có, Dice và Jaccard của ca đó được quy ước bằng 0. Quy ước này áp dụng như nhau cho toàn bộ năm cấu hình.